

UNIVERSITÀ POLITECNICA DELLE MARCHE

FACOLTÀ DI INGEGNERIA

Dipartimento di Ingegneria dell'Informazione

Corso di Laurea Magistrale in Ingegneria Informatica e dell'Automazione



PROGETTO DI DATA SCIENCE

**Classificazione, Clustering e Serie Temporalì con l'utilizzo del dataset
WeatherAUS**

Autori

Valeria Cannone

Giada Remedia

Alessandro Pettinaro

ANNO ACCADEMICO 2025-2026

1	Introduzione	1
1.1	Contesto e motivazione del progetto	1
1.2	Obiettivi e approccio analitico	1
1.3	Organizzazione del lavoro	2
2	Dataset e Analisi Esplorativa dei Dati	3
2.1	WeatherAUS	3
2.2	Qualità dei dati e valori mancanti	4
2.3	Struttura temporale	5
2.4	La variabile target e lo sbilanciamento delle classi	7
2.5	Distribuzione delle variabili numeriche	8
2.6	Analisi della multicollinearità	8
2.6.1	Diagnostica della multicollinearità	9
2.6.2	Rimozione iterativa delle variabili collineari	10
2.7	Relazione tra le variabili meteorologiche e il target	12
2.8	Pattern temporali, geografici e categoriali	12
2.9	Sintesi e implicazioni per la modellazione	14
3	Classificazione	16
3.1	Strumenti per la classificazione	16
3.1.1	Metriche di valutazione	16
3.1.2	Modelli di classificazione	17
3.1.3	Tecniche per lo sbilanciamento	18
3.1.4	Soglia di decisione e calibrazione	18
3.1.5	Importanza delle variabili	19
3.2	Preparazione dei dati	19
3.2.1	Pulizia e ordinamento	19
3.2.2	Pipeline di trasformazione	19
3.2.3	Suddivisione in training e test set	20
3.2.4	Configurazioni di feature	20
3.3	Protocollo sperimentale	21
3.3.1	Validazione incrociata temporale	21
3.3.2	Metrica di selezione	22
3.3.3	Matrice dei costi	22
3.3.4	Baseline di riferimento	22

3.3.5	Fasi dell'esperimento	22
3.4	Risultati	24
3.4.1	Verifica delle configurazioni	24
3.4.2	Baseline	24
3.4.3	Confronto dei modelli	24
3.4.4	Strategie per lo sbilanciamento	25
3.4.5	Ottimizzazione degli iperparametri	26
3.4.6	Soglia di decisione	27
3.4.7	Valutazione sul test set	27
3.5	Studio di ablazione	30
3.6	Quantificazione del leakage temporale	31
3.7	Importanza delle feature	31
3.7.1	Esempi di inferenza	33
3.8	Conclusioni e limiti	33
4	Clustering	35
4.1	Strumenti per il clustering	35
4.1.1	Analisi delle componenti principali	35
4.1.2	K-Means	36
4.1.3	DBSCAN	36
4.1.4	Indici di valutazione interni	36
4.1.5	Indici di valutazione esterni	37
4.1.6	t-SNE	37
4.2	Preprocessing dei dati	37
4.2.1	Selezione delle feature	38
4.2.2	Campionamento	38
4.2.3	Trasformazione e standardizzazione	38
4.3	Protocollo sperimentale	39
4.3.1	Scelta del numero di cluster	39
4.3.2	Scelta parametri di DBSCAN	39
4.3.3	Confronto fra gli algoritmi	40
4.3.4	Interpretazione e validazione a posteriori	40
4.4	Risultati	40
4.4.1	Struttura dei dati	40
4.4.2	Scelta del numero di cluster	42
4.4.3	Partizione di K-Means	43
4.4.4	DBSCAN	43
4.4.5	Confronto visivo con t-SNE	46
4.4.6	Interpretazione dei regimi	47
4.4.7	Validazione con variabili esterne	48
4.5	Conclusioni e limiti	50
5	Serie temporali	52
5.1	Strumenti per l'analisi delle serie temporali	52
5.1.1	Notazione	53
5.1.2	Stazionarietà e test ADF e KPSS	53
5.1.3	Decomposizione classica	54
5.1.4	Autocorrelazione: ACF e PACF	54
5.1.5	ARIMA, SARIMA e SARIMAX	54
5.1.6	Criteri di selezione, metriche di errore e diagnostica	55
5.2	Preparazione della serie	56

5.3	Protocollo sperimentale	57
5.3.1	Validazione a origine mobile	58
5.3.2	Baseline e variabili esogene	58
5.4	Risultati	59
5.4.1	Analisi esplorativa	59
5.4.2	Stazionarietà	60
5.4.3	Identificazione degli ordini	61
5.4.4	Termine deterministico	62
5.4.5	Stima e selezione degli ordini	62
5.4.6	Diagnostica dei residui	63
5.4.7	Validazione a origine mobile	64
5.4.8	Valutazione sul test	65
5.4.9	Variabili esogene e rischio di lookahead	67
5.4.10	Previsione dei mesi successivi	68
5.5	Sintesi e limiti	69
6	Conclusioni	71
6.1	Sintesi dei risultati	71
6.2	Considerazioni metodologiche	72
6.3	Sviluppi futuri	73

Elenco delle figure

2.1	Percentuale di valori mancanti per variabile, calcolata sulle 142 193 osservazioni con target valido.	4
2.2	Percentuale di valori mancanti per stazione nelle quattro colonne critiche. Le righe interamente scure corrispondono a stazioni che non misurano mai la variabile.	6
2.3	Autocorrelazione media di <code>RainTomorrow</code> all'interno della stessa stazione, al variare della distanza in giorni.	7
2.4	Distribuzione delle classi di <code>RainTomorrow</code>	7
2.5	Distribuzione di frequenza delle variabili numeriche.	8
2.6	Matrice di correlazione di Pearson tra le variabili numeriche, comprese le binarie <code>RainToday</code> e <code>RainTomorrow</code> codificate in 0/1.	9
2.7	VIF delle variabili originali (sinistra) e dopo la riparametrizzazione (destra). Le linee tratteggiate indicano le soglie 5 e 10.	11
2.8	Distribuzioni delle sei variabili più correlate con il target, suddivise per classe di <code>RainTomorrow</code>	13
2.9	Persistenza della pioggia e andamento stagionale del target.	13
2.10	Percentuale di giorni seguiti da pioggia per direzione della raffica massima. La linea tratteggiata indica la media globale.	14
2.11	Percentuale di giorni seguiti da pioggia per ciascuna delle 49 stazioni.	15
3.1	Schema della validazione incrociata temporale a 5 fold con embargo (ampiezza non in scala). Il test set non partecipa ad alcuna fase di sviluppo.	21
3.2	F_1 (sinistra) e costo atteso (destra) al variare della soglia sulla finestra di validazione temporale, configurazione D.	27
3.3	Curva di calibrazione di XGBoost sul test set, configurazione D, con 10 intervalli per quantili.	28
3.4	Matrice di confusione, curva ROC e curva Precision-Recall di XGBoost sul test set, configurazione D.	29
3.5	Permutation importance sul test set, configurazione D.	32
4.1	Varianza spiegata da ciascuna componente (sinistra) e varianza cumulata (destra).	41
4.2	Metodo del gomito, Silhouette e ARI rispetto alla stagione al variare di k	42
4.3	Cluster K-Means ($k = 4$) e relativi centroidi proiettati sulle prime due componenti principali.	43

4.4	k-distance plot con <code>min_samples = 24</code> . Le linee tratteggiate indicano il 50°, il 90° e il 95° percentile delle distanze.	44
4.5	Risultato di DBSCAN ($\epsilon = 1,5$) proiettato sulle prime due componenti principali, con gli outlier in rosso.	45
4.6	Proiezione t-SNE di 3 000 giornate colorate secondo K-Means (sinistra) e DBSCAN (destra).	46
4.7	Profilo standardizzato dei cluster K-Means, come scostamento di ogni variabile dalla media globale.	47
4.8	(a) Percentuale di giornate seguite da pioggia per cluster, con la media globale del 22%. (b) Distribuzione dei mesi all'interno di ciascun cluster.	48
4.9	A sinistra il cluster K-Means dominante per stazione, a destra la percentuale di giornate seguite da pioggia.	50
5.1	Temperatura pomeridiana media mensile a Sydney e suddivisione in training (febbraio 2008 – giugno 2015) e test (luglio 2015 – giugno 2017).	57
5.2	Training: a sinistra gli anni sovrapposti, a destra la distribuzione della temperatura per mese.	59
5.3	Decomposizione additiva del training in componente osservata, trend, stagionalità e residuo.	60
5.4	Training differenziato stagionalmente al ritardo 12.	61
5.5	ACF e PACF del training differenziato stagionalmente.	61
5.6	Diagnostica dei residui del modello stimato sul training: residui standardizzati, istogramma con densità stimata, Q-Q plot e correlogramma.	64
5.7	Previsione a 24 mesi del modello scelto sul test, con intervallo di confidenza al 95% e baseline naïve stagionale.	66
5.8	Errore di previsione mese per mese sul test (previsto meno reale), con le sovrastime in rosso e le sottostime in blu.	67
5.9	Valori reali sul test e previsioni del modello univariato e del modello con esogene nei due scenari.	68
5.10	Previsione dei dodici mesi successivi con intervallo di confidenza al 95%. . .	69

Elenco delle tabelle

2.1	Feature derivate introdotte per ridurre la multicollinearità.	11
2.2	Confronto della multicollinearità prima e dopo la riparametrizzazione.	11
3.1	Configurazioni dello studio di ablazione. La colonna <i>Var.</i> indica il numero di variabili di partenza, la colonna <i>Feature</i> il numero di colonne dopo il preprocessing, comprensivo di variabili numeriche, indicatori di mancanza e variabili <i>one-hot</i>	20
3.2	Multicollinearità delle variabili numeriche della configurazione D, confrontata con le variabili originali.	24
3.3	Prestazioni delle baseline sul test set.	24
3.4	PR-AUC in validazione incrociata temporale (media $\pm$ deviazione standard sui 5 fold).	25
3.5	Strategie per lo sbilanciamento nella configurazione D, valutate sulla finestra di validazione di 5 000 righe con regressione logistica come stimatore di base.	25
3.6	F_1 e costo atteso delle strategie nelle quattro configurazioni.	25
3.7	Iperparametri ottimali e PR-AUC in validazione incrociata dopo l'ottimizzazione.	26
3.8	Calibrazione della soglia.	27
3.9	Sensibilità alla matrice dei costi, configurazione D. La soglia è la mediana delle soglie a costo minimo sui 5 fold della validazione temporale; le prestazioni sono misurate sul test.	28
3.10	Prestazioni di XGBoost sul test set per la classe pioggia, con soglia calibrata. Il costo è calcolato con $C_{01} = 3$ e $C_{10} = 1$	28
3.11	Confronto fra soglia di default 0,5 e soglia calibrata sul test set.	29
3.12	Studio di ablazione. La PR-AUC in CV è riportata sia con i parametri di partenza di XGBoost (confronto dei modelli), usata per la selezione, sia dopo l'ottimizzazione.	30
3.13	Split casuale con leakage contro split cronologico, a parità di modello e soglia. La colonna Δ indica la sovrastima dovuta allo split casuale, calcolata sui valori non arrotondati.	31
3.14	Permutation importance sul test set (calo medio di PR-AUC) nelle configurazioni A e D. Prime dodici variabili.	32
4.1	Coefficienti delle variabili sulle prime due componenti principali (<i>loadings</i>).	41

4.2	Indici di valutazione di K-Means al variare di k . In grassetto l'ottimo di ciascun indice interno. Le ultime due colonne, rispetto alla stagione, sono riportate a titolo informativo e non entrano nella scelta di k	42
4.3	Criteri aggiuntivi per la scelta di k	42
4.4	Analisi di sensibilità di DBSCAN al raggio ε , con <code>min_samples = 24</code>	44
4.5	Profilo medio delle giornate classificate come outlier da DBSCAN ($\varepsilon = 1,5$) rispetto al nucleo, ordinato per scarto assoluto.	45
4.6	Giornate classificate come outlier da DBSCAN in ciascun cluster K-Means. . .	46
4.7	Valori medi delle variabili per i quattro cluster K-Means, in unità di misura originali.	47
4.8	Percentuale di giornate con pioggia nel giorno stesso (<code>RainToday</code>) per cluster. .	49
4.9	Indici di corrispondenza fra la partizione K-Means ($k = 4$) ed etichette esterne, dove 0 indica corrispondenza casuale e 1 coincidenza perfetta.	49
5.1	Comportamento di ACF e PACF per i processi elementari.	54
5.2	Modelli confrontati nella validazione a origine mobile.	58
5.3	Test di stazionarietà sul training, prima e dopo la differenziazione stagionale. .	61
5.4	Confronto dei modelli candidati con deriva, stimati sul training.	62
5.5	Coefficienti del SARIMA(1,0,0)(0,1,1) ₁₂ con deriva, stimati sul training. . . .	63
5.6	Test di Ljung-Box sui residui, esclusi i primi 12 e con 3 gradi di libertà sottratti. .	64
5.7	MAE (°C) della validazione a origine mobile sul training: previsioni a 12 mesi da 5 origini.	65
5.8	Prestazioni sui 24 mesi di test.	66
5.9	Coefficienti del SARIMAX con variabili esogene, stimati sul training.	67
5.10	Modello con esogene nei due scenari, confrontato con il modello univariato e la baseline sul test. Lo scenario oracolo usa i valori futuri reali delle covariate e non costituisce una previsione realizzabile.	68
5.11	Previsione dei dodici mesi successivi alla fine della serie, in gradi Celsius, con intervallo di confidenza al 95%.	69

1.1 Contesto e motivazione del progetto

L'analisi dei dati meteorologici è uno dei campi di applicazione più stimolanti del Data Science e del Machine Learning. I fenomeni atmosferici sono complessi, fortemente stagionali e variabili nello spazio, e richiedono strumenti in grado di cogliere sia le relazioni istantanee fra grandezze fisiche sia la loro evoluzione nel tempo.

Il progetto conduce uno studio analitico sul dataset *weatherAUS*, che raccoglie le rilevazioni meteorologiche giornaliere di 49 stazioni australiane fra novembre 2007 e giugno 2017. L'obiettivo è mostrare come un unico insieme di dati possa essere affrontato da prospettive diverse, applicando le tre principali famiglie di tecniche del Data Science e adottando in ciascuna un protocollo sperimentale che eviti risultati ottimistici.

1.2 Obiettivi e approccio analitico

Il lavoro si articola in tre analisi, precedute da una fase comune di esplorazione dei dati.

- **Apprendimento supervisionato (classificazione binaria):** Si prevede se poverà il giorno successivo (*RainTomorrow*) a partire dalle condizioni del giorno corrente. Il problema presenta due difficoltà principali: lo sbilanciamento delle classi, con circa il 22% di giornate piovose, e la dipendenza temporale fra le osservazioni, che impone uno split cronologico. Oltre al confronto fra algoritmi e fra strategie per lo sbilanciamento, si conduce uno studio di ablazione su quattro configurazioni di feature, per misurare l'effetto delle scelte suggerite dall'analisi esplorativa.
- **Apprendimento non supervisionato (clustering):** Si raggruppano le giornate in base alla sola somiglianza delle condizioni atmosferiche, per individuare regimi meteorologici ricorrenti. Le etichette di tempo, luogo e pioggia non sono usate dagli algoritmi e servono solo a validare a posteriori i gruppi trovati.
- **Analisi delle serie temporali:** Si modella la temperatura pomeridiana media mensile a Sydney, identificando trend e stagionalità con la metodologia di Box-Jenkins. Il modello SARIMA scelto è confrontato con una baseline naïve stagionale, con modelli a stagionalità deterministica e con varianti SARIMAX che includono variabili esogene.

1.3 Organizzazione del lavoro

Il progetto si compone delle seguenti parti.

- *Analisi esplorativa e preparazione dei dati*(EDA, Capitolo 2).
- Quattro versioni per la *classificazione* che condividono la stessa pipeline e differiscono solo per l'insieme di feature (Capitolo 3):
 - Configurazione di riferimento;
 - Rimozione della ridondanza fra `Rainfall` e `RainToday`;
 - Recupero di `Sunshine` e `Cloud3pm`;
 - Riparametrizzazione anti-collinearità.

Lo studio delle strategie per lo sbilanciamento comprende anche l'algoritmo *cost-sensitive* MetaCost.

- *Clustering*: individuazione dei regimi meteorologici (Capitolo 4).
- *Serie temporali*: modellazione e previsione della serie temporale (Capitolo 5).

Le tre analisi trattano la struttura temporale dei dati in modo diverso, coerentemente con il loro scopo. Nella classificazione le giornate sono istanze di un problema predittivo, ma la loro dipendenza temporale è gestita esplicitamente con uno split cronologico e una validazione incrociata temporale. Nel clustering, che descrive la struttura dei dati senza prevedere il futuro, le giornate sono trattate come punti di uno spazio di feature e il campionamento casuale è legittimo. Nelle serie temporali, infine, la dipendenza sequenziale è l'oggetto stesso della modellazione.

Dataset e Analisi Esplorativa dei Dati

In questo capitolo viene presentato il dataset utilizzato e l'analisi esplorativa condotta prima della modellazione. L'obiettivo è verificare la qualità dei dati e individuare le caratteristiche strutturali che vincolano le scelte di preparazione dei dati e di modellazione dei capitoli successivi.

2.1 WeatherAUS

Il dataset utilizzato è *weatherAUS*, che raccoglie osservazioni meteorologiche giornaliere rilevate dal Bureau of Meteorology australiano in 49 località, nel periodo compreso tra il 1° novembre 2007 e il 25 giugno 2017. Esso contiene 145 460 righe e 23 variabili.

La classificazione è condotta sull'intero dataset con target valido (142 193 osservazioni). Per contenere i tempi di calcolo, solo lo studio comparativo delle strategie per lo sbilanciamento e MetaCost lavorano su un sottoinsieme, cioè sulle ultime 20 000 righe del training set, suddivise in ordine cronologico in 15 000 righe di addestramento e 5 000 di validazione. Il clustering opera invece su un campione casuale di 10 000 giornate estratto dalle 120 381 osservazioni complete sulle 12 variabili impiegate, mentre l'analisi delle serie temporali considera la sola stazione di Sydney.

Ogni riga del dataset corrisponde a una giornata di una stazione, e la coppia (*Date*, *Location*) identifica univocamente l'osservazione, dato che il controllo non ha rilevato né righe duplicate né chiavi ripetute. Le variabili si possono raggruppare in sei categorie.

- **Informazioni temporali e geografiche**, ovvero la data dell'osservazione (*Date*) e la stazione di rilevamento (*Location*).
- **Temperatura e pressione**, con le temperature minima e massima giornaliere (*MinTemp*, *MaxTemp*) e i valori di temperatura e pressione atmosferica, ridotta al livello medio del mare, registrati alle 9:00 e alle 15:00 (*Temp9am*, *Temp3pm*, *Pressure9am*, *Pressure3pm*).
- **Precipitazione, evaporazione e insolazione**, cioè i millimetri di pioggia caduti nelle 24 ore fino alle 9:00 (*Rainfall*), l'evaporazione da vasca nello stesso intervallo (*Evaporation*) e le ore di sole della giornata (*Sunshine*).
- **Vento**, con direzione e velocità della raffica più forte della giornata (*WindGustDir*, *WindGustSpeed*) e direzione e velocità media del vento alle 9:00 e alle 15:00 (*WindDir9am*,

WindDir3pm, WindSpeed9am, WindSpeed3pm). Le direzioni sono variabili categoriche a 16 modalità, corrispondenti ai punti della rosa dei venti.

- **Umidità e nuvolosità**, ovvero l’umidità relativa alle 9:00 e alle 15:00 (Humidity9am, Humidity3pm) e la copertura nuvolosa negli stessi orari, espressa in oktas¹ (Cloud9am, Cloud3pm).
- **Variabili binarie**, cioè RainToday, che vale Yes quando Rainfall è strettamente maggiore di 1 mm, e la variabile target RainTomorrow, che indica lo stesso evento nel giorno successivo.

Alcune versioni del dataset includono anche la colonna RISK_MM, ovvero la pioggia del giorno successivo da cui RainTomorrow è derivata direttamente, che costituirebbe un caso evidente di *data leakage*. Nella versione utilizzata la colonna è assente.

2.2 Qualità dei dati e valori mancanti

La colonna target RainTomorrow presenta circa il 2,2% di valori mancanti, per cui la prima operazione effettuata è stata eliminare le 3 267 righe prive di target, che non possono essere usate né per l’addestramento né per la valutazione. Il dataset si riduce così a 142 193 osservazioni, sulle quali sono calcolate le statistiche che seguono. Fa eccezione l’analisi della struttura temporale (Sezione 2.3), condotta sul dataset completo per non introdurre interruzioni artificiali nelle serie.

La percentuale di valori mancanti per variabile è riportata in Figura 2.1. Per la maggior parte delle colonne la quota resta sotto il 10%, con un massimo di 9,9% per le due pressioni, mentre quattro colonne presentano percentuali molto elevate, ovvero Sunshine (47,7%), Evaporation (42,8%), Cloud3pm (40,2%) e Cloud9am (37,7%).




Figura 2.1: Percentuale di valori mancanti per variabile, calcolata sulle 142 193 osservazioni con target valido.

Per capire l’origine di queste assenze è stata costruita una mappa di calore che incrocia le stazioni con la percentuale di mancanti nelle quattro colonne critiche (Figura 2.2). Da

¹Unità di misura della copertura nuvolosa, espressa in ottavi di volta celeste coperta da nubi.

qui, possiamo osservare che le righe interamente scure mostrano che i mancanti sono in larga parte **strutturali**, perché molte stazioni non dispongono dello strumento e non rilevano mai la variabile. Non misurano mai Sunshine in 19 stazioni su 49, Evaporation 16, Cloud9am e Cloud3pm 12 ciascuna.

In questa situazione, imputare i valori per una stazione priva dello strumento significa assegnarle misure mai effettuate. La scelta non è però scontata, perché Sunshine, Cloud3pm e Cloud9am sono rispettivamente la prima, la terza e la quarta variabile per correlazione con il target (Sezione 2.6). Le colonne critiche sono quindi trattate in modo diverso a seconda dell'analisi. Evaporation, debolmente correlata con il target ($|r| = 0,119$), e Cloud9am, che misura la stessa grandezza di Cloud3pm con una correlazione più bassa, sono scartate ovunque. Nel clustering, che richiede osservazioni complete, vengono scartate anche Sunshine e Cloud3pm. Nella classificazione, invece, le due alternative sono confrontate sperimentalmente (Capitolo 3), con una configurazione che scarta tutte e quattro le colonne e una che recupera Sunshine e Cloud3pm imputandole con la mediana e affiancando a ciascuna un indicatore binario di mancanza, così che il modello possa distinguere un valore imputato da una misura reale.

2.3 Struttura temporale

Il dataset è un *panel* di 49 serie storiche giornaliere, una per stazione. Il file non è ordinato per data e le stazioni non coprono tutte lo stesso intervallo. Nel primo mese, novembre 2007, è attiva una sola stazione, mentre a regime il numero mensile di stazioni attive ha mediana 46. Le serie più brevi sono quelle di Nhil, Katherine e Uluru, che iniziano nel marzo 2013 e contano 1 578 osservazioni ciascuna. I primi anni sono quindi rappresentati da un sottoinsieme di stazioni, aspetto da tenere presente nella definizione dello split cronologico.

La pioggia presenta inoltre una marcata dipendenza temporale. La Figura 2.3 mostra l'autocorrelazione di RainTomorrow calcolata separatamente per ciascuna stazione e poi mediata,

$$\bar{\rho}(k) = \frac{1}{L} \sum_{\ell=1}^L \text{corr}(y_{\ell,t}, y_{\ell,t+k}), \quad (2.1)$$

dove $y_{\ell,t}$ è il target della stazione ℓ nel giorno t , k è il ritardo misurato in osservazioni successive della stessa stazione e $L = 49$. L'autocorrelazione vale 0,292 a un giorno, scende a 0,126 a due giorni e a 0,077 a tre, per poi stabilizzarsi intorno a 0,05 fino a due settimane (0,054 a sette giorni). La dipendenza diretta si esaurisce quindi in pochi giorni, mentre la componente residua è verosimilmente dovuta alla stagionalità, che rende simili giornate vicine anche in assenza di un legame meteorologico diretto.

Esiste infine un legame deterministico fra righe consecutive della stessa stazione, perché il target di un giorno coincide con la variabile RainToday del giorno successivo,

$$\text{RainTomorrow}(\ell, t) = \text{RainToday}(\ell, t + 1) \quad (2.2)$$

La relazione è verificata senza eccezioni su tutte le 142 017 coppie di giorni consecutivi con entrambi i valori disponibili.

Queste due proprietà hanno conseguenze dirette sulla valutazione dei modelli. Con uno split casuale il giorno t potrebbe finire nel test set mentre i giorni $t - 1$ e $t + 1$ della stessa stazione restano nel training set, per cui i due insiemi non sarebbero indipendenti e le metriche risulterebbero ottimistiche. Per questo motivo la suddivisione in training e test è **cronologica**, con un taglio su una data, e la validazione incrociata è temporale. Il legame fra righe consecutive impone inoltre cautela nella costruzione di eventuali feature di ritardo o medie mobili, dato che quelle calcolate sui giorni precedenti sono legittime,




Figura 2.2: Percentuale di valori mancanti per stazione nelle quattro colonne critiche. Le righe interamente scure corrispondono a stazioni che non misurano mai la variabile.




Figura 2.3: Autocorrelazione media di RainTomorrow all’interno della stessa stazione, al variare della distanza in giorni.

mentre uno spostamento nel verso sbagliato o una finestra che includa il giorno successivo introdurrebbe direttamente il target fra le feature.

2.4 La variabile target e lo sbilanciamento delle classi

Analizzando la distribuzione del target in codifica binaria viene evidenziato in Figura 2.4 uno sbilanciamento marcato, con 110 316 giornate senza pioggia (77,6%) contro 31 877 giornate piovose (22,4%), pari a un rapporto di circa 3,5 : 1.




Figura 2.4: Distribuzione delle classi di RainTomorrow.

La proporzione di giorni piovosi è stabile negli anni. Considerando gli anni completi dal 2009 al 2016 oscilla tra il 20,4% del 2014 e il 24,7% del 2011, mentre il valore del 2007 (31,1%) non è significativo perché basato su sole 61 osservazioni. Uno split cronologico produce quindi training e test set con proporzioni di classe confrontabili, senza bisogno di stratificazione.

Lo sbilanciamento rende l’*accuracy* inadeguata come metrica principale, dato che un classificatore banale che prevede sempre “No pioggia” otterrebbe già un’*accuracy* del 77,6% senza riconoscere alcun giorno di pioggia. I modelli saranno quindi valutati tramite Precision, Recall e F1-score sulla classe minoritaria, affiancati dall’area sotto la curva ROC (ROC-AUC) e sotto la curva Precision-Recall (PR-AUC).

2.5 Distribuzione delle variabili numeriche

Gli istogrammi delle variabili continue sono riportati in Figura 2.5 e mostrano che pressione, temperature e umidità hanno distribuzioni approssimativamente simmetriche, con indici di asimmetria compresi fra $-0,5$ e $0,25$, mentre le velocità del vento presentano una moderata asimmetria positiva (da $0,63$ a $0,87$). Le variabili legate alle precipitazioni sono invece fortemente asimmetriche, perché *Rainfall* ha la massa concentrata sullo zero e una lunga coda destra, con un indice di asimmetria (*skewness*) pari a $9,89$, e anche *Evaporation* supera la soglia convenzionale di 2 con un valore di $3,75$.




Figura 2.5: Distribuzione di frequenza delle variabili numeriche.

Code così pesanti possono penalizzare i modelli lineari, poiché pochi valori estremi dominano la stima dei coefficienti. Per *Rainfall* è quindi indicata la trasformazione $\log(1 + x)$, che comprime la coda ed è definita anche per i valori nulli. Questo permette di ottenere un effetto rilevante perché la correlazione con il target passa da $0,239$ a $0,344$. Per i modelli ad albero la trasformazione è invece influente, dato che le suddivisioni dipendono solo dall'ordinamento dei valori.

2.6 Analisi della multicollinearità

Per l'analisi delle correlazioni tra le variabili del dataset è stata usata la matrice di correlazione di Pearson (Figura 2.6), che mostra le relazioni attese dal punto di vista fisico, in particolare la forte correlazione tra misure della stessa grandezza, come ad esempio $r = 0,985$ tra *MaxTemp* e *Temp3pm*, $0,961$ tra le due pressioni e $0,902$ tra *MinTemp* e *Temp9am*.

Le variabili più correlate con *RainTomorrow* sono:

- Sunshine ($|r| = 0,451$, relazione negativa);
- Humidity3pm ($|r| = 0,446$, relazione positiva);
- Cloud3pm (0,382) e Cloud9am (0,317);
- RainToday (0,313).

Meno ore di sole e più umidità e nuvolosità si associano quindi a una maggiore probabilità di pioggia il giorno successivo, mentre le temperature risultano debolmente legate al target, con valori compresi fra 0,026 (Temp9am) e 0,192 (Temp3pm).




Figura 2.6: Matrice di correlazione di Pearson tra le variabili numeriche, comprese le binarie RainToday e RainTomorrow codificate in 0/1.

2.6.1 Diagnostica della multicollinearità

La matrice di correlazione descrive però solo relazioni a coppie, mentre una variabile può essere poco correlata con ciascuna delle altre e risultare comunque quasi ricostruibile da una loro combinazione lineare. Su questo dataset la multicollinearità è attesa, perché le stesse grandezze sono misurate due volte al giorno oppure come minimo e massimo. Il fenomeno non compromette l'accuratezza dei modelli ad albero, ma gonfia la varianza delle stime e rende instabili i coefficienti dei modelli lineari.

Sono stati usati due indicatori complementari. Il primo è il *Variance Inflation Factor* (VIF) della variabile j ,

$$\text{VIF}_j = \frac{1}{1 - R_j^2}, \quad (2.3)$$

dove R_j^2 è il coefficiente di determinazione della regressione di x_j su tutti gli altri predittori. In particolare, valori superiori a 5 indicano una collinearità moderata e quelli superiori a 10 indicano collinearità elevata. Il calcolo sfrutta l'identità

$$\text{VIF}_j = [\mathbf{R}^{-1}]_{jj}, \quad (2.4)$$

con $\mathbf{R}$ matrice di correlazione dei predittori. Poiché la correlazione opera su variabili già centrate e standardizzate, il risultato coincide con quello della regressione con intercetta e si evita un errore frequente, perché omettendo la colonna costante le variabili con media lontana da zero come `Pressure9am` (circa 1017 hPa) otterrebbero VIF nell'ordine delle migliaia, privi di significato.

Il secondo indicatore è il *Condition Index* (CI), una diagnostica globale basata sugli autovalori λ di $\mathbf{R}$,

$$\text{CI} = \sqrt{\frac{\lambda_{\max}}{\lambda_{\min}}}, \quad (2.5)$$

con valori superiori a 10 indicativi di collinearità *moderata* e superiori a 30 di collinearità *severa*.

Dal calcolo sono esclusi il target, perché la sua correlazione con le feature è il segnale da sfruttare e non un difetto, e `Month`, che nei modelli entra come variabile categorica. Sono escluse anche le quattro colonne sparse, perché il calcolo della VIF richiede righe complete e includendole si scenderebbe a 58 090 righe (40,9%), provenienti quasi solo dalle stazioni meglio strumentate.

Sui 13 predittori rimanenti, calcolati su 119 590 righe complete, pari all'84,1% del totale, il Condition Index vale 21,22, che indica una collinearità moderata, e con le colonne sparse sale a 23,70. I VIF (Figura 2.7, figura a sinistra) superano la soglia di 10 per cinque variabili, cioè `Temp3pm` (53,13), `MaxTemp` (44,69), `Temp9am` (22,14), `Pressure9am` (19,33) e `Pressure3pm` (18,99). `MinTemp` (9,01) e `Humidity3pm` (6,28) si collocano nella fascia moderata e vento e pioggia, invece, non presentano problemi.

2.6.2 Rimozione iterativa delle variabili collineari

La procedura diagnostica classica adottata elimina a ogni passo la variabile con VIF più alto e ricalcola l'indice, finché tutti i valori scendono sotto la soglia. Applicata con soglia 5, essa rimuove quattro variabili (`Temp3pm`, `Temp9am`, `Pressure9am` e `MaxTemp`) e porta il Condition Index a 3,33, ma considera solo la collinearità e ignora il potere predittivo. Il limite emerge proprio all'interno delle coppie ridondanti, perché viene scartata `Pressure9am` ($|r| = 0,246$ con il target) e mantenuta `Pressure3pm` (0,226), poi viene scartata `MaxTemp` (0,159) mantenendo `MinTemp` (0,084). In entrambi i casi sopravvive la variabile meno informativa.

Riparametrizzazione. Le alternative a questo fenomeno sono:

- Eliminare i predittori ridondanti, con i limiti appena visti;
- Combinare i predittori tramite PCA, perdendo l'interpretazione fisica delle componenti;

- Sostituire ogni gruppo collineare con grandezze derivate dotate di significato proprio.

La terza opzione è la più adatta al caso in esame, per cui ogni grandezza misurata due volte viene espressa come un **livello** e una **variazione**, secondo la Tabella 2.1.

Tabella 2.1: Feature derivate introdotte per ridurre la multicollinearità.

Feature	Definizione	Significato
TempRange	MaxTemp – MinTemp	escursione termica
PressureTrend	Pressure3pm – Pressure9am	tendenza barometrica
HumidityTrend	Humidity3pm – Humidity9am	evoluzione dell'umidità
WindTrend	WindSpeed3pm – WindSpeed9am	rinforzo o calo del vento
RainfallLog	$\log(1 + \text{Rainfall})$	pioggia su scala compressa

L'escursione termica tende a essere ampia con cielo sereno e ridotta con copertura nuvolosa, mentre una pressione in calo nel corso della giornata segnala tipicamente l'avvicinarsi di un fronte. Si conservano i valori delle 15:00, più vicini al momento della previsione, e si scartano quelli delle 9:00. Per pressione, umidità e vento la trasformazione è invertibile, quindi l'informazione resta la stessa e cambia solo la base in cui è espressa, mentre per le temperature si conservano MaxTemp e TempRange, da cui MinTemp è ricostruibile, e si omettono Temp9am e Temp3pm perché quasi ridondanti con minima e massima. Si omette infine RainToday, sostituita da RainfallLog.




Figura 2.7: VIF delle variabili originali (sinistra) e dopo la riparametrizzazione (destra). Le linee tratteggiate indicano le soglie 5 e 10.

Tabella 2.2: Confronto della multicollinearità prima e dopo la riparametrizzazione.

	N. variabili	VIF max	VIF mediano	N. VIF > 10	CI
Originali	13	53,13	6,28	5	21,22
Riparametrizzate	10	3,28	1,89	0	4,30

Come riportato in Tabella 2.2, la riparametrizzazione elimina la multicollinearità, perché il VIF massimo scende da 53,13 a 3,28 e il Condition Index da 21,22 a 4,30. Il segnale predittivo non va perso e per alcune feature aumenta, dato che TempRange raggiunge $|r| = 0,338$ con il target, più del doppio di qualsiasi singola temperatura, RainfallLog arriva a 0,344 contro lo 0,239 di Rainfall e lo 0,313 di RainToday, e anche HumidityTrend risulta informativa (0,268).

Non tutte le derivate confermano però le attese fisiche, perché PressureTrend ha una correlazione lineare debole (0,080), inferiore a quella dei livelli di pressione, e WindTrend

è di fatto scorrelata dal target (0,004). Poiché la trasformazione è invertibile questo non comporta perdita di informazione, e la tendenza barometrica potrebbe comunque risultare utile in relazioni non lineari o in combinazione con altre variabili.

I modelli ad albero sono poco sensibili alla collinearità, mentre per i modelli lineari la riparametrizzazione rende i coefficienti stabili e interpretabili. Per verificare se porti un beneficio anche in termini predittivi, essa è valutata come configurazione autonoma nello studio di ablazione del Capitolo 3, dove risulta la configurazione migliore in validazione incrociata, seppure con un margine contenuto.

Ridondanza tra Rainfall e RainToday. RainToday è una funzione deterministica di Rainfall, dato che coincide con la condizione $\text{Rainfall} > 1$ mm nel 100% delle righe, e le due colonne sono mancanti esattamente nelle stesse 1406 osservazioni, per cui imputarle entrambe significherebbe applicare due volte la stessa imputazione. Nessuna delle due costituisce leakage, poiché entrambe si riferiscono al giorno t mentre il target riguarda il giorno $t + 1$.

L'indicazione per la modellazione è di mantenere la sola Rainfall trasformata con $\log(1 + x)$, che contiene tutta l'informazione della binaria e ne aggiunge l'intensità, dato che un albero può ricostruire da solo la soglia a 1 mm mentre un modello lineare beneficia della distinzione fra 2 e 200 mm. Come visto sopra, la versione logaritmica è anche la più correlata con il target delle tre.

2.7 Relazione tra le variabili meteorologiche e il target

La Figura 2.8 confronta, mediante boxplot, le distribuzioni delle sei variabili più correlate con il target nelle due classi, escludendo RainToday in quanto binaria. Le differenze sono nette, perché nei giorni che precedono la pioggia la mediana di Sunshine scende da 9,4 a 4,3 ore, quella di Humidity3pm sale dal 47% al 70% e quella di Humidity9am dal 67% all'80%, la copertura nuvolosa mediana passa da 4 a 7 oktas sia alle 9:00 sia alle 15:00 e la mediana di Pressure9am cala da 1018,5 a 1014,3 hPa.

Tre delle sei variabili (Sunshine, Cloud3pm e Cloud9am) sono fra quelle a mancanza strutturale. Le relative distribuzioni sono calcolate solo sulle stazioni che le misurano e documentano il contributo informativo a cui si rinuncia scartandole.

2.8 Pattern temporali, geografici e categoriali

Dall'analisi emergono quattro pattern.

Persistenza della pioggia. Come mostrato in Figura 2.9(a), se oggi non piove la probabilità di pioggia il giorno successivo è del 15,2%, mentre se oggi piove sale al 46,4%, cioè più del triplo. Questa persistenza suggerisce una seconda baseline, la regola "domani come oggi", la cui accuracy (76,2%) è addirittura inferiore a quella della regola "non piove mai" (77,6%), ma che a differenza di quest'ultima individua una parte dei giorni piovosi. È quindi il riferimento più significativo in termini di F1 e ribadisce quanto l'accuracy sia fuorviante su questo problema.

Stagionalità. Il mese, estratto dalla colonna Date, mostra un andamento stagionale di ampiezza contenuta (Figura 2.9(b)). La frequenza di giorni seguiti da pioggia raggiunge il massimo nell'inverno australe, con il 26,9% a luglio, il 26,2% a giugno e il 25,3% ad agosto,




Figura 2.8: Distribuzioni delle sei variabili più correlate con il target, suddivise per classe di RainTomorrow.

mentre i valori minimi si registrano a gennaio (19,3%) e ottobre (19,6%), per un'escursione complessiva di circa 7,6 punti percentuali. Il mese viene quindi usato come predittore categorico, mentre la data non entra fra le feature e serve solo a definire lo split cronologico.




Figura 2.9: Persistenza della pioggia e andamento stagionale del target.

Direzione del vento. Anche la direzione della raffica massima è informativa (Figura 2.10). Le raffiche dai settori nord-occidentali, da W a N, precedono un giorno di pioggia nel 26,7–28,5% dei casi, con il valore più alto per NW, mentre quelle dai settori orientali (ENE, E, ESE) scendono al 14,9–16,4%, a fronte di una media globale del 22,4%. Le tre variabili di direzione sono codificate con *one-hot encoding* nella fase di modellazione.

Differenze tra località. La Figura 2.11 evidenzia la variabilità più ampia fra tutti i fattori considerati, con una frequenza di giorni seguiti da pioggia compresa tra il 6,8% di Woomera e il 36,5% di Portland. Le stazioni costiere o meridionali come Portland, Walpole (33,7%) e




Figura 2.10: Percentuale di giorni seguiti da pioggia per direzione della raffica massima. La linea tratteggiata indica la media globale.

Cairns (31,8%) superano il 30%, mentre quelle dell'entroterra arido come Woomera, Uluru (7,6%) e Alice Springs (8,1%) restano intorno o sotto l'8%. Anche Location viene quindi inclusa fra i predittori tramite *one-hot encoding*.

2.9 Sintesi e implicazioni per la modellazione

L'analisi esplorativa ha condotto alle seguenti scelte.

- **Validazione.** La pioggia è autocorrelata (0,29 a un giorno) e il target di un giorno coincide con `RainToday` del giorno successivo, per cui lo split è cronologico e la validazione incrociata è temporale.
- **Metriche.** Lo sbilanciamento di circa 3,5 : 1 rende l'accuracy fuorviante, al punto che la baseline di persistenza risulta inferiore in accuracy a quella che non prevede mai pioggia. Si adottano Precision, Recall e F1 sulla classe positiva, ROC-AUC e PR-AUC, con il confronto rispetto alle due baseline.
- **Valori mancanti.** `Sunshine`, `Evaporation`, `Cloud9am` e `Cloud3pm` sono mancanti in modo strutturale per intere stazioni. `Evaporation` e `Cloud9am` sono sempre scartate, mentre per `Sunshine` e `Cloud3pm`, molto correlate con il target, l'eliminazione e l'imputazione con indicatore di mancanza sono confrontate nello studio di ablazione.
- **Ridondanze.** Temperature e pressioni sono fortemente collineari (VIF fino a 53, Condition Index 21) e `RainToday` è funzione di `Rainfall`. Per i modelli ad albero la collinearità non incide sull'accuratezza, mentre la riparametrizzazione in livelli e variazioni riduce il Condition Index a 4,3, con feature come `TempRange` e `RainfallLog` più informative delle originali, ed è valutata come configurazione a sé nello studio di ablazione.
- **Predittori categorici.** `Location`, `Month` e le tre direzioni del vento risultano informativi e sono codificati con *one-hot encoding*, mentre `Date` non è usata come feature.
- **Leakage.** La colonna `RISK_MM` è assente e il rischio residuo, di natura temporale, è gestito tramite lo split cronologico.




Figura 2.11: Percentuale di giorni seguiti da pioggia per ciascuna delle 49 stazioni.

L'obiettivo di questo capitolo è prevedere se piovgerà il giorno successivo, rappresentato dalla variabile binaria `RainTomorrow`, a partire dalle condizioni meteorologiche registrate nella giornata corrente. A tale scopo vengono confrontati diversi modelli predittivi.

L'analisi esplorativa ha evidenziato due proprietà che condizionano l'intero protocollo sperimentale. La prima è lo sbilanciamento del target, ovvero circa il 78% delle giornate non è seguito da pioggia, e l'accuracy diventa quindi una metrica inadeguata. La seconda è che le osservazioni formano un panel di serie storiche con autocorrelazione marcata, per cui uno split casuale produrrebbe metriche ottimistiche.

L'EDA ha inoltre lasciato aperte due scelte sulle feature che riguardano il recupero delle colonne a mancanza strutturale più correlate con il target e la riparametrizzazione delle variabili collineari. Per rispondere in modo sperimentale, la classificazione è stata svolta in quattro versioni che condividono esattamente la stessa pipeline e differiscono solo per l'insieme di feature. Il confronto costituisce uno **studio di ablazione**, in cui ogni configurazione introduce una sola modifica rispetto alla precedente, così che la differenza di prestazioni osservata sia attribuibile a quella modifica e non a un insieme di cambiamenti sovrapposti.

Il capitolo è organizzato come segue. La Sezione 3.1 introduce le metriche, i modelli e le tecniche utilizzate. Le Sezioni 3.2 e 3.3 descrivono la preparazione dei dati e il protocollo sperimentale, comuni alle quattro configurazioni. La Sezione 3.4 riporta i risultati di ciascuna fase. Seguono lo studio di ablazione, la quantificazione del leakage temporale, l'analisi dell'importanza delle feature e le conclusioni.

3.1 Strumenti per la classificazione

Prima di descrivere il procedimento vengono introdotte le metriche con cui si valutano le previsioni, i modelli confrontati, le tecniche per trattare lo sbilanciamento, il criterio per scegliere la soglia di decisione e il metodo usato per misurare l'importanza delle variabili.

3.1.1 Metriche di valutazione

In tutto il capitolo la classe positiva è la pioggia (`RainTomorrow = 1`). Confrontando la classe prevista con quella reale, ogni osservazione ricade in una delle quattro celle della **matrice di confusione**: veri positivi (TP , pioggia prevista e osservata), falsi positivi (FP , falso allarme), falsi negativi (FN , pioggia non prevista) e veri negativi (TN).

A partire da queste quantità si definiscono le metriche utilizzate:

$$\text{Accuracy} = \frac{TP + TN}{N}, \quad \text{Precision} = \frac{TP}{TP + FP}, \quad \text{Recall} = \frac{TP}{TP + FN}, \quad (3.1)$$

$$F_1 = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}. \quad (3.2)$$

La Precision indica quale frazione degli allarmi corrisponde a una giornata effettivamente piovosa, mentre la Recall indica quale frazione dei giorni di pioggia viene individuata. L' F_1 è la media armonica delle due. Con classi sbilanciate l'accuracy è poco informativa, perché un modello che prevede sempre la classe maggioritaria ottiene già circa il 78%.

Le metriche precedenti dipendono dalla **soglia di decisione** t utilizzata dal modello per restituire una probabilità $\hat{p}(x)$ e prevedere pioggia se $\hat{p}(x) \geq t$. Per valutare il modello indipendentemente dalla soglia si usano due curve, ottenute facendo variare t fra 0 e 1:

- la **curva ROC**, che riporta la Recall contro il tasso di falsi positivi $FP/(FP + TN)$. L'area sottesa (**ROC-AUC**) è la probabilità che una giornata piovosa scelta a caso riceva un punteggio più alto di una non piovosa; vale 0,5 per un classificatore casuale;
- la **curva Precision-Recall**, che riporta la Precision contro la Recall. La sua area viene stimata con l'*average precision*,

$$AP = \sum_n (R_n - R_{n-1}) P_n, \quad (3.3)$$

dove P_n e R_n sono Precision e Recall alla n -esima soglia. Nel seguito questa quantità è indicata come **PR-AUC**. Per un classificatore casuale la Precision è costante e pari alla quota di positivi, per cui il riferimento è la prevalenza della pioggia, circa 0,22.

3.1.2 Modelli di classificazione

Sono confrontati quattro classificatori, due lineari e due basati su insiemi di alberi, per verificare se il problema richieda di cogliere relazioni non lineari fra le variabili. Questi sono:

- **Regressione logistica**. Modella la probabilità di pioggia come funzione sigmoide di una combinazione lineare delle feature, $P(y = 1 \mid x) = \sigma(\beta_0 + \beta^\top x)$ con $\sigma(z) = 1/(1 + e^{-z})$. I coefficienti sono stimati per massima verosimiglianza con regolarizzazione L_2 .
- **SVM lineare**. Cerca l'iperpiano che separa le due classi con il margine massimo. La SVM restituisce un punteggio e non una probabilità; per questo i punteggi vengono trasformati in probabilità in $[0, 1]$ con una funzione sigmoide stimata su dati di validazione (calibrazione di Platt). Normalizzare i punteggi con minimo e massimo produrrebbe invece una scala fragile, non confrontabile fra addestramenti diversi.
- **Random Forest**. Addestra molti alberi di decisione su campioni bootstrap del training, considerando a ogni nodo solo un sottoinsieme casuale di feature, e calcola la media delle previsioni. La media riduce la varianza del singolo albero.
- **XGBoost**. Implementa il *gradient boosting* in cui gli alberi sono aggiunti in sequenza, e ciascuno è addestrato a correggere gli errori residui dell'insieme costruito fino a quel momento. Il *learning rate* riduce il contributo di ogni albero, rendendo l'apprendimento più graduale.

3.1.3 Tecniche per lo sbilanciamento

Con una classe positiva minoritaria, un modello addestrato per massimizzare la verosimiglianza tende a favorire la classe più frequente. Le tecniche confrontate intervengono in punti diversi del processo.

- **Ripesatura delle classi:** ogni osservazione pesa nella funzione di perdita in proporzione inversa alla frequenza della propria classe, per cui un errore su un giorno di pioggia costa circa 3,5 volte un errore su un giorno sereno. I dati non vengono modificati.
- **SMOTE** (*Synthetic Minority Over-sampling Technique*): genera nuove osservazioni positive interpolando fra un esempio della classe minoritaria e uno dei suoi vicini più prossimi della stessa classe, fino a bilanciare le classi.
- **NearMiss** (versione 2): riduce la classe maggioritaria conservando i negativi la cui distanza media dai positivi più lontani è minima, cioè quelli più vicini alla zona di confine fra le classi.
- **LDA** (*Linear Discriminant Analysis*): proietta i dati sulla direzione che massimizza la separazione fra le medie delle due classi rispetto alla variabilità interna. Con due classi la proiezione ha una sola dimensione, su cui viene poi addestrata una regressione logistica pesata.
- **MetaCost:** descritto di seguito, agisce sulle etichette anziché sui pesi o sui dati.

MetaCost. MetaCost rende *cost-sensitive* un classificatore qualsiasi modificando le etichette del training anziché l'algoritmo. Data una matrice dei costi C , in cui C_{ij} è il costo di predire la classe i quando la classe vera è j , il procedimento si articola in tre passi:

1. Si addestrano m copie del classificatore su campioni bootstrap del training e si stima, per ogni esempio x , la probabilità media $P(j | x)$ di ciascuna classe;
2. A ogni esempio si assegna la classe che minimizza il costo atteso,

$$\hat{y}(x) = \arg \min_i \sum_j P(j | x) C_{ij}; \quad (3.4)$$

3. Il classificatore definitivo viene addestrato sull'intero training con le nuove etichette.

In questo modo gli esempi positivi incerti, che un modello standard classificherebbe come negativi, vengono rietichettati come positivi quando mancarli costerebbe troppo.

3.1.4 Soglia di decisione e calibrazione

Un classificatore probabilistico produce una stima $\hat{p}(x)$ della probabilità di pioggia, e la decisione dipende dalla soglia t . Se il modello è **ben calibrato**, cioè se fra le giornate a cui assegna probabilità p piove effettivamente in una frazione p dei casi, la teoria delle decisioni fornisce la soglia che minimizza il costo atteso. Prevedere pioggia costa in media $C_{10}(1 - p)$, dovuto ai falsi allarmi, mentre non prevederla costa $C_{01}p$; conviene quindi prevedere pioggia quando $C_{01}p \geq C_{10}(1 - p)$, ovvero per

$$p \geq t^* = \frac{C_{10}}{C_{10} + C_{01}}. \quad (3.5)$$

La soglia di default 0,5 corrisponde al caso di costi simmetrici.

La calibrazione di un modello si verifica con la **curva di calibrazione**. In particolare, le previsioni sono raggruppate in intervalli di probabilità e, per ciascun intervallo, la probabilità media prevista è confrontata con la frequenza osservata di pioggia. Un modello perfettamente calibrato giace sulla diagonale, mentre punti sopra la diagonale indicano che il modello sottostima la probabilità e punti sotto che la sovrastima.

3.1.5 Importanza delle variabili

Per capire su quali variabili si basa il modello si usa la **permutation importance**. Per ogni variabile i suoi valori vengono permutati casualmente sul test set, rompendo il legame con il target ma conservandone la distribuzione, e si misura il calo della metrica rispetto al modello originale. Più il calo è ampio, più il modello dipende da quella variabile. La permutazione è ripetuta 5 volte e se ne riporta la media.

Il calcolo avviene sulle colonne originali, prima della codifica *one-hot*, così che ogni variabile categorica riceva un unico punteggio. L'importanza nativa degli alberi basata sul *gain* è stata evitata perché tende a favorire le variabili con molte categorie, e `Location` ne ha 49. Come metrica si usa la PR-AUC, che non dipende dalla soglia, così che l'importanza non risenta della soglia di decisione adottata.

3.2 Preparazione dei dati

Questa sezione descrive le operazioni che trasformano il dataset grezzo in training e test set pronti per i modelli. Le operazioni sono identiche nelle quattro configurazioni, fatta eccezione per l'insieme di colonne selezionate (Sezione 3.2.4).

3.2.1 Pulizia e ordinamento

Come prima operazione si verifica che la colonna `RISK_MM`, ovvero la quantità di pioggia del giorno successivo da cui il target è derivato, sia assente dal dataset, dato che la sua presenza costituirebbe un *leakage* diretto. Vengono poi eliminate le 3 267 righe prive di target, lasciando 142 193 osservazioni, ordinate per data e località.

L'ordinamento è necessario perché il dataset originale è ordinato per stazione e non per data, per cui qualsiasi taglio per posizione mescolerebbe periodi diversi. La data non viene usata come predittore, ma solo per definire il taglio fra training e test; la stagionalità entra nel modello attraverso il mese (`Month`), trattato come variabile categorica.

3.2.2 Pipeline di trasformazione

Per prevenire il *data leakage*, tutte le trasformazioni sono inserite in un'unica *pipeline* di pre-processing, che applica a ogni gruppo di variabili la trasformazione appropriata. In questo modo imputazione, standardizzazione e codifica vengono riaddestrate all'interno di ogni fold di validazione e non usano mai informazione proveniente dai dati di validazione o di test.

Le variabili numeriche sono imputate con la mediana, più robusta della media su distribuzioni asimmetriche, e poi standardizzate. A ogni variabile che presenta valori mancanti nel training viene inoltre affiancato un indicatore binario di mancanza, utile in quanto, senza indicatore, una misura reale pari alla mediana e un dato assente diventerebbero indistinguibili.

Le variabili categoriche (`Location`, `WindGustDir`, `WindDir9am`, `WindDir3pm` e `Month`) sono imputate con la moda e codificate con *one-hot encoding*, ignorando le categorie non vi-

ste in addestramento. Si ottengono, infine, 109 variabili indicatrici comprendenti 49 località, 3×16 direzioni del vento e 12 mesi.

3.2.3 Suddivisione in training e test set

Data la dipendenza temporale documentata nell'EDA, la suddivisione è **cronologica** e non casuale. La data di taglio è quella che si trova all'80% delle righe ordinate, e la separazione avviene su quella data e non sulla posizione, così che una stessa giornata non possa finire in parte nel training e in parte nel test. Si ottengono:

- **Training set:** 113 748 righe, dal 1 novembre 2007 al 9 novembre 2015;
- **Test set:** 28 445 righe, dal 10 novembre 2015 al 25 giugno 2017.

La quota di giornate piovose è pressoché identica nei due insiemi (22,44% contro 22,32%), coerentemente con la stabilità annuale del target osservata nell'EDA, per cui non è necessaria alcuna stratificazione. Sul training si contano 88 220 giornate senza pioggia e 25 528 con pioggia, con un rapporto di 3,46 : 1. Si è inoltre verificato che non vi sia sovrapposizione temporale fra i due insiemi e che nessuna località compaia solo nel test.

3.2.4 Configurazioni di feature

Nella fase di esplorazione sono state individuate quattro colonne a mancanza strutturale, assenti per intere stazioni, ovvero *Sunshine*, *Evaporation*, *Cloud9am* e *Cloud3pm*.

Evaporation e *Cloud9am* sono scartate in tutte le configurazioni. Restano aperte tre scelte:

- Conservare sia *Rainfall* sia *RainToday*, che sono ridondanti;
- Recuperare *Sunshine* e *Cloud3pm*, fortemente correlate con il target;
- Sostituire le coppie di variabili collineari con la riparametrizzazione descritta nella Sezione 2.6.

Le quattro configurazioni della Tabella 3.1 introducono queste modifiche una alla volta.

Tabella 3.1: Configurazioni dello studio di ablazione. La colonna *Var.* indica il numero di variabili di partenza, la colonna *Feature* il numero di colonne dopo il preprocessing, comprensivo di variabili numeriche, indicatori di mancanza e variabili *one-hot*.

Config.	Modifica rispetto alla precedente	Var.	Feature
A – Baseline	Scartate le quattro colonne sparse, con tutte le altre variabili originali comprese <i>Rainfall</i> e <i>RainToday</i>	13	135
B – Rimozione ridondanze	<i>Rainfall</i> e <i>RainToday</i> sostituite da <i>RainfallLog</i>	12	133
C – Recupero variabili correlate	Reintrodotte <i>Sunshine</i> e <i>Cloud3pm</i> , imputate con indicatore di mancanza	14	137
D – Riparametrizzazione	Coppie collineari sostituite da livello e variazione (<i>TempRange</i> , <i>PressureTrend</i> , <i>HumidityTrend</i> , <i>WindTrend</i>), con <i>MinTemp</i> , <i>Temp9am</i> , <i>Temp3pm</i> e le misure delle 9:00 scartate	12	133

Nella configurazione D livello, variazione e misura delle 9:00 della stessa grandezza non compaiono mai insieme. In caso contrario, ad esempio, `Pressure9am`, `Pressure3pm` e `PressureTrend` sarebbero legate da una dipendenza lineare esatta, con VIF infinito. L'effetto della riparametrizzazione sulla multicollinearità è verificato nella Sezione 3.4.1.

3.3 Protocollo sperimentale

Prima di confrontare qualsiasi modello occorre stabilire come misurarne le prestazioni in modo affidabile. Le due proprietà emerse dall'EDA, la dipendenza temporale e lo sbilanciamento del target, pongono tre domande, ovvero su quali dati stimare le prestazioni durante lo sviluppo, con quale metrica confrontare i modelli e come tenere conto del diverso peso dei due tipi di errore. Le sottosezioni seguenti rispondono a ciascuna di esse. In tutte le fasi di sviluppo il test set resta escluso e viene usato una sola volta, per la valutazione finale.

3.3.1 Validazione incrociata temporale

Nella validazione incrociata classica le osservazioni sono assegnate ai fold in modo casuale, per cui il modello può essere addestrato su giornate successive a quelle su cui viene valutato. Con dati autocorrelati le giornate vicine si somigliano, e il modello sfrutta questa somiglianza anziché imparare a fare previsioni, quindi la stima risulta ottimistica, come quantificato nella Sezione 3.6.

Si utilizza quindi una validazione incrociata temporale con 5 fold. Il training, ordinato per data, viene diviso in blocchi consecutivi di circa 19 000 righe; al fold k il modello è addestrato su tutti i blocchi precedenti e validato sul blocco successivo (Figura 3.1). La finestra di addestramento cresce quindi da un fold all'altro, e ogni valutazione riproduce la condizione reale di utilizzo, in cui il modello conosce solo il passato e deve prevedere il futuro.

Poiché ogni giorno contiene più stazioni, il confine fra addestramento e validazione cadrebbe in mezzo a giornate fortemente dipendenti fra loro. Per evitarlo si introduce un *embargo* di 500 righe, che vengono scartate fra i due insiemi. Con una mediana di 46 stazioni attive al giorno, l'embargo corrisponde a circa 11 giorni.




Figura 3.1: Schema della validazione incrociata temporale a 5 fold con embargo (ampiezza non in scala). Il test set non partecipa ad alcuna fase di sviluppo.

Questo schema è usato per il confronto dei modelli, per la ricerca degli iperparametri e per la calibrazione della soglia.

3.3.2 Metrica di selezione

Fra le metriche introdotte nella Sezione 3.1.1, per confrontare i modelli serve una misura che non dipenda dalla soglia di decisione, che verrà scelta solo in seguito, e che resti informativa con classi sbilanciate. La scelta ricade sulla **PR-AUC**. A differenza dell' F_1 e della ROC-AUC, nel primo caso non richiede di fissare una soglia e nel secondo caso non premia la corretta classificazione dei numerosi giorni senza pioggia, perché sia la Precision sia la Recall si concentrano sulla classe positiva. Il riferimento per un classificatore casuale è la prevalenza della pioggia, circa 0,22.

3.3.3 Matrice dei costi

Le metriche precedenti trattano allo stesso modo i due tipi di errore, mentre nel contesto applicativo mancare una giornata di pioggia è più grave di un falso allarme. Per tenerne conto si adotta una matrice dei costi che assegna costo 3 al falso negativo e costo 1 al falso positivo:

$$C = \begin{pmatrix} 0 & 3 \\ 1 & 0 \end{pmatrix}, \quad C_{ij} = \text{costo di predire } i \text{ quando la classe vera è } j. \quad (3.6)$$

Il costo atteso è riportato per 1 000 osservazioni,

$$\text{Costo}/1000 = \frac{1000 (C_{01} FN + C_{10} FP)}{N}, \quad (3.7)$$

ed è usato sia per scegliere la soglia di decisione sia come metrica aggiuntiva di valutazione. Per un modello calibrato, dall'equazione (3.5) la soglia ottimale attesa è $t^* = 1/(1+3) = 0,25$. Poiché il valore 3 è un'ipotesi di progetto, la sensibilità dei risultati a questa scelta viene analizzata separatamente.

3.3.4 Baseline di riferimento

Un valore di F_1 o di costo non è interpretabile in assoluto, ma solo rispetto a un termine di paragone. Sono state quindi definite due regole elementari, che non richiedono addestramento e sono indipendenti dalla configurazione di feature:

- **maggioranza:** prevede sempre “non piove”;
- **persistenza:** prevede pioggia domani se oggi è piovuto, trattando i mancanti di `RainToday` come assenza di pioggia. È la regola più semplice che sfrutta la dipendenza temporale del fenomeno.

Un modello deve superare in modo netto la persistenza per giustificare la propria complessità.

3.3.5 Fasi dell'esperimento

L'esperimento si articola in fasi successive, in cui ogni fase utilizza l'esito della precedente. L'intera sequenza è ripetuta in modo identico per ciascuna delle quattro configurazioni.

1. **Confronto dei modelli.** I quattro classificatori della Sezione 3.1.2 sono valutati con la validazione temporale a 5 fold, usando la PR-AUC. Random Forest e XGBoost usano 150 alberi, XGBoost con *learning rate* 0,1; la validazione interna del calibratore della SVM è anch'essa temporale (validazione temporale a 3 fold), per non reintrodurre leakage all'interno del fold. In questa fase nessun modello applica ripesature delle classi. Il modello con la PR-AUC media più alta viene usato nelle fasi successive.

2. **Strategie per lo sbilanciamento.** Questa fase è uno studio a sé, che non modifica il modello scelto al passo precedente ma serve a decidere come trattare lo sbilanciamento nel modello finale. Le tecniche della Sezione 3.1.3 sono applicate alla regressione logistica anziché a XGBoost, per due motivi. Il primo è computazionale: sette strategie, di cui MetaCost richiede di addestrare più copie del modello, ripetute per quattro configurazioni, avrebbero con XGBoost tempi molto più lunghi. Il secondo è che la regressione logistica è il modello più sensibile allo sbilanciamento, per cui l'effetto delle diverse strategie risulta più evidente. Per contenere i tempi di calcolo, lo studio usa le ultime 20 000 righe del training, divise in ordine cronologico in 15 000 righe di addestramento e 5 000 di validazione. MetaCost, che è il più oneroso, usa 8 campioni bootstrap.
3. **Ottimizzazione degli iperparametri.** Gli iperparametri del modello scelto sono ottimizzati con una ricerca a griglia. In dettaglio, ogni combinazione della griglia viene valutata sui 5 fold temporali e si sceglie quella con la PR-AUC media più alta. La griglia comprende 24 combinazioni, per un totale di 120 addestramenti:
 - $\text{max_depth} \in \{4, 6, 8\}$, profondità massima degli alberi;
 - $\text{learning_rate} \in \{0,05; 0,1\}$, contributo di ogni albero;
 - $\text{min_child_weight} \in \{1, 5\}$, peso minimo dei nodi foglia;
 - $\text{subsample} \in \{0,8; 1,0\}$, frazione di righe campionate per albero.
4. **Calibrazione della soglia.** La soglia non può essere scelta sul test set. Con la validazione temporale non è nemmeno possibile ottenere una previsione *out-of-fold* per ogni riga del training, perché le righe iniziali servono solo per l'addestramento e non compaiono mai in validazione. La soglia viene quindi scelta in due passi:
 - (a) *finestra di validazione*: il modello ottimizzato è addestrato sul primo 80% del training (90 999 righe, fino a luglio 2014) e valutato sull'ultimo 20% (22 749 righe, da luglio 2014 a novembre 2015), calcolando F_1 e costo atteso per soglie da 0,05 a 0,95 con passo 0,01;
 - (b) *soglia robusta*: poiché una singola finestra produce stime rumorose, la soglia a costo minimo viene cercata su ciascuno dei 5 fold della validazione temporale e si adotta la mediana dei valori ottenuti.

Il criterio è la minimizzazione del costo atteso; la soglia che massimizza l' F_1 è calcolata solo come confronto. Con la stessa procedura sui 5 fold si valuta anche la sensibilità alla matrice dei costi. Per diversi valori di C_{01} la soglia è la mediana delle soglie a costo minimo sui fold e viene poi applicata al test, senza mai essere cercata sul test.
5. **Valutazione finale.** Il modello ottimizzato viene riaddestrato sull'intero training e applicato una sola volta al test set con la soglia calibrata. Le prestazioni sono confrontate con le baseline e con quelle ottenute alla soglia di default 0,5.

Scelta della configurazione. La configurazione finale è scelta in base alla PR-AUC in validazione incrociata, calcolata sul solo training. Le metriche di test sono riportate a scopo descrittivo e non guidano la selezione, altrimenti il test set perderebbe il suo ruolo di stima imparziale.

Analisi aggiuntive. A completamento, ciascuna configurazione calcola la permutation importance sul test set (Sezione 3.1.5), applica il modello ad alcune giornate estratte a caso dal test come esempio di inferenza e quantifica il leakage temporale. Per quest'ultimo, lo stesso modello viene valutato con uno split casuale stratificato 80/20, in cui training e test si sovrappongono nel tempo, e con lo split cronologico adottato, a parità di iperparametri e soglia. In questo confronto XGBoost è addestrato con le classi ripesate in base al loro rapporto nel rispettivo training, e quindi differisce dal modello finale. I valori assoluti non sono confrontabili con quelli della valutazione finale, mentre lo è la differenza fra i due split.

3.4 Risultati

I risultati sono presentati seguendo l'ordine delle fasi della Sezione 3.3.5. Quando possibile, le tabelle riportano affiancate le quattro configurazioni.

3.4.1 Verifica delle configurazioni

La Tabella 3.2 confronta la multicollinearità delle variabili numeriche originali con quella del set adottato nella configurazione D. Il VIF massimo scende da 52,74 a 3,87 (`Humidity3pm`), seguito da `WindSpeed3pm` (3,37) e `TempRange` (2,95), e il Condition Index da 21,05 a 5,01. Nessuna variabile supera la soglia di collinearità moderata. Il set D contiene una variabile in più perché include anche `Sunshine` e `Cloud3pm`; per lo stesso motivo i valori differiscono leggermente da quelli dell'EDA, ma la conclusione non cambia.

Tabella 3.2: Multicollinearità delle variabili numeriche della configurazione D, confrontata con le variabili originali.

	N. variabili	VIF max	VIF mediano	N. VIF > 10	CI
Originali	11	52,74	8,97	5	21,05
Configurazione D	12	3,87	2,13	0	5,01

3.4.2 Baseline

La Tabella 3.3 riporta le prestazioni delle due baseline sul test set e mostra concretamente il problema dell'accuracy; in particolare, la regola di maggioranza ottiene il valore più alto senza riconoscere una sola giornata di pioggia. La persistenza individua il 44% dei giorni piovosi con Precision di circa 0,45 e riduce il costo atteso del 26% rispetto alla maggioranza. È questo il riferimento che i modelli devono superare.

Tabella 3.3: Prestazioni delle baseline sul test set.

Baseline	Accuracy	F1	Recall	Costo / 1000
Maggioranza	0,777	0,000	0,000	669,6
Persistenza	0,753	0,444	0,441	496,5

3.4.3 Confronto dei modelli

XGBoost risulta il modello migliore in tutte e quattro le configurazioni (Tabella 3.4), seguito da Random Forest, regressione logistica e SVM lineare. Il divario fra il primo e l'ultimo, circa

4 punti di PR-AUC, supera ampiamente la deviazione standard fra i fold. I due modelli ad albero, invece, precedono i due lineari, a indicare che le relazioni non lineari fra le variabili portano informazione utile.

Tabella 3.4: PR-AUC in validazione incrociata temporale (media $\pm$ deviazione standard sui 5 fold).

Modello	A	B	C	D
Regressione logistica	0,700 $\pm$ 0,015	0,701 $\pm$ 0,015	0,709 $\pm$ 0,014	0,710 $\pm$ 0,014
SVM lineare	0,693 $\pm$ 0,017	0,695 $\pm$ 0,018	0,704 $\pm$ 0,016	0,705 $\pm$ 0,016
Random Forest	0,711 $\pm$ 0,014	0,714 $\pm$ 0,013	0,721 $\pm$ 0,013	0,726 $\pm$ 0,014
XGBoost	0,731 $\pm$ 0,012	0,731 $\pm$ 0,012	0,737 $\pm$ 0,012	0,741 $\pm$ 0,011

L'ordinamento dei modelli non cambia da una configurazione all'altra, e anche l'effetto delle feature è coerente, infatti, il passaggio da B a C migliora tutti e quattro i classificatori di 0,7–0,8 punti, per cui il beneficio del recupero di *Sunshine* e *Cloud3pm* non dipende dall'algoritmo. XGBoost è quindi adottato come modello di riferimento per le fasi successive.

3.4.4 Strategie per lo sbilanciamento

La Tabella 3.5 riporta il dettaglio per la configurazione D, mentre la Tabella 3.6 riassume F_1 e costo atteso nelle quattro configurazioni.

Tabella 3.5: Strategie per lo sbilanciamento nella configurazione D, valutate sulla finestra di validazione di 5 000 righe con regressione logistica come stimatore di base.

Strategia	F1	Precision	Recall	Costo / 1000
Nessun trattamento	0,505	0,740	0,384	390,8
Ripesatura	0,586	0,530	0,654	318,6
SMOTE	0,591	0,534	0,661	313,8
NearMiss + SMOTE	0,517	0,394	0,753	374,0
LDA + ripesatura	0,581	0,521	0,657	321,6
MetaCost (LR)	0,597	0,566	0,630	313,6
MetaCost + LDA	0,588	0,563	0,616	321,2

Tabella 3.6: F_1 e costo atteso delle strategie nelle quattro configurazioni.

Strategia	F1				Costo / 1000			
	A	B	C	D	A	B	C	D
Nessun trattamento	0,498	0,495	0,515	0,505	395,2	396,8	384,8	390,8
Ripesatura	0,573	0,575	0,587	0,586	330,4	329,6	317,8	318,6
SMOTE	0,575	0,574	0,590	0,591	330,2	331,0	315,6	313,8
NearMiss + SMOTE	0,511	0,510	0,440	0,517	382,0	382,6	478,0	374,0
LDA + ripesatura	0,562	0,561	0,563	0,581	339,2	340,0	337,0	321,6
MetaCost (LR)	0,574	0,579	0,580	0,597	334,6	330,6	328,0	313,6
MetaCost + LDA	0,565	0,563	0,570	0,588	340,0	341,4	335,4	321,2

Il quadro che emerge è coerente in tutte le configurazioni.

- **Senza trattamento:** la regressione logistica ottiene la Precision più alta (0,74) ma riconosce meno del 40% dei giorni di pioggia, con il costo atteso peggiore. È il comportamento tipico di un modello che, per massimizzare la verosimiglianza, segue la classe maggioritaria.
- **Ripesatura, SMOTE e MetaCost:** migliorano l' F_1 di 7–9 punti e riducono il costo del 16–20%, con differenze reciproche di 1–2 punti su una validazione di 5 000 righe. La strategia migliore cambia da una configurazione all'altra; per l' F_1 è SMOTE in A e C e MetaCost in B e D; per il costo è SMOTE in A e C, la ripesatura in B e MetaCost in D.
- **MetaCost:** offre un compromesso più equilibrato fra Precision e Recall rispetto alla ripesatura ed è la strategia a costo minimo nella configurazione D, sia pure con un margine trascurabile su SMOTE (313,6 contro 313,8).
- **NearMiss + SMOTE:** è la combinazione meno affidabile. Raggiunge la Recall più alta, ma con Precision sotto 0,40, e nella configurazione C degrada fino a F_1 pari a 0,440 con un costo di 478, peggiore della regressione non trattata. L'undersampling aggressivo scarta informazione utile e rende il risultato instabile.

Poiché la ripesatura è competitiva con il ricampionamento senza generare dati sintetici, il modello finale non applica SMOTE né MetaCost. L'asimmetria dei costi viene invece incorporata nella calibrazione della soglia, che per un classificatore probabilistico produce lo stesso effetto di spostamento del compromesso fra Precision e Recall.

Questa conclusione va letta tenendo conto di due limiti. Il primo è che lo studio è condotto con la regressione logistica: indica quale strategia funziona meglio per un modello lineare, ma non garantisce che l'ordinamento sia lo stesso per XGBoost, che è meno sensibile allo sbilanciamento e su cui la scelta viene poi applicata. Il secondo è che SMOTE e NearMiss operano dopo il preprocessing, quindi anche sulle variabili *one-hot*, dove i campioni sintetici possono assumere valori frazionari (ad esempio 0,3 su una località) su variabili che dovrebbero valere 0 o 1. L'alternativa rigorosa sarebbe SMOTE-NC, che interpola solo le variabili numeriche e assegna alle categoriche la modalità più frequente fra i vicini.

3.4.5 Ottimizzazione degli iperparametri

La Tabella 3.7 riporta gli iperparametri scelti. Il guadagno rispetto ai parametri di partenza è modesto, fra 0,3 e 0,4 punti di PR-AUC, e la combinazione scelta è quasi identica nelle quattro configurazioni. Sia la profondità massima sia il *learning rate* ottimali cadono però al bordo superiore della griglia, per cui alberi più profondi o un numero maggiore di iterazioni potrebbero portare un ulteriore miglioramento.

Tabella 3.7: Iperparametri ottimali e PR-AUC in validazione incrociata dopo l'ottimizzazione.

Config.	max_depth	learning rate	min_child_weight	subsample	PR-AUC (CV)
A	8	0,1	5	0,8	0,7340
B	8	0,1	1	0,8	0,7337
C	8	0,1	1	0,8	0,7417
D	8	0,1	1	0,8	0,7443

3.4.6 Soglia di decisione

La Figura 3.2 mostra F_1 e costo atteso al variare della soglia sulla finestra di validazione, e la Tabella 3.8 riassume le soglie ottenute. Le colonne indicate come *finestra* si riferiscono alla singola finestra di validazione, le altre alla ricerca sui 5 fold.




Figura 3.2: F_1 (sinistra) e costo atteso (destra) al variare della soglia sulla finestra di validazione temporale, configurazione D.

Tabella 3.8: Calibrazione della soglia.

Config.	Max F1 (finestra)	Min costo (finestra)	Soglie per fold	Adottata	Dev. std
A	0,30 (F1 0,642)	0,20 (costo 286)	0,22 0,23 0,25 0,27 0,21	0,23	0,022
B	0,27 (F1 0,645)	0,23 (costo 285)	0,22 0,21 0,25 0,24 0,22	0,22	0,015
C	0,28 (F1 0,649)	0,20 (costo 276)	0,20 0,20 0,23 0,20 0,21	0,20	0,012
D	0,26 (F1 0,649)	0,17 (costo 275)	0,19 0,22 0,20 0,21 0,20	0,20	0,010

Le soglie adottate cadono fra 0,20 e 0,23, molto al di sotto del valore di default. Quella che massimizza F_1 è sistematicamente più alta di quella a costo minimo, come atteso, dato che F_1 pesa allo stesso modo falsi negativi e falsi positivi. La dispersione fra i fold si riduce passando dalla configurazione A (0,022) alla D (0,010): le configurazioni con più informazione producono probabilità più stabili nel tempo.

Il risultato è coerente con la soglia teorica $t^* = 0,25$ dell'equazione (3.5). Nella configurazione D la curva di calibrazione sul test set (Figura 3.3) è molto vicina alla diagonale, con una lieve sottostima nella fascia 0,2–0,4, e la soglia empirica (0,20) risulta di poco inferiore a quella teorica. La curva del costo è però quasi piatta fra 0,17 e 0,25, per cui le due soglie producono risultati equivalenti.

Sensibilità alla matrice dei costi. La Tabella 3.9 riporta, per la configurazione D, l'effetto di diversi valori del costo del falso negativo. Al crescere di C_{01} la soglia scende e la Recall aumenta, dal 56% con costi simmetrici al 94% quando una pioggia mancata costa dieci volte un falso allarme; la Precision scende in parallelo da 0,74 a 0,38. L' F_1 massimo si otterrebbe con $C_{01} = 2$, ma l' F_1 non è l'obiettivo del progetto. La tabella mostra soprattutto che la matrice dei costi è la leva con cui una preferenza applicativa si traduce in un punto operativo del modello.

3.4.7 Valutazione sul test set

La Tabella 3.10 riporta le prestazioni di XGBoost sul test set, con la soglia calibrata, nelle quattro configurazioni.




Figura 3.3: Curva di calibrazione di XGBoost sul test set, configurazione D, con 10 intervalli per quantili.

Tabella 3.9: Sensibilità alla matrice dei costi, configurazione D. La soglia è la mediana delle soglie a costo minimo sui 5 fold della validazione temporale; le prestazioni sono misurate sul test.

Costo FN	Soglia	Precision	Recall	F1
1	0,49	0,739	0,555	0,634
2	0,32	0,635	0,691	0,662
3	0,20	0,534	0,809	0,643
5	0,15	0,476	0,866	0,614
10	0,08	0,379	0,938	0,540

Tabella 3.10: Prestazioni di XGBoost sul test set per la classe pioggia, con soglia calibrata. Il costo è calcolato con $C_{01} = 3$ e $C_{10} = 1$.

Config.	Soglia	Precision	Recall	F1	ROC-AUC	PR-AUC	Accuracy	Costo / 1000
A	0,23	0,557	0,779	0,650	0,884	0,733	0,81	286,1
B	0,22	0,547	0,788	0,646	0,884	0,733	0,81	287,5
C	0,20	0,531	0,813	0,642	0,885	0,733	0,80	285,8
D	0,20	0,534	0,809	0,643	0,886	0,737	0,80	285,6

Le quattro configurazioni risultano molto vicine; possiamo osservare che la PR-AUC varia di meno di mezzo punto, la ROC-AUC di 0,2 punti e il costo atteso resta fra 285,6 e 287,5. Le differenze su F_1 e Recall dipendono in larga parte dalla soglia, perché C e D, con soglia 0,20, individuano più giorni di pioggia al prezzo di una Precision inferiore.

La configurazione D, scelta come modello finale nella Sezione 3.5, individua circa l'81% dei 6349 giorni di pioggia del test con una Precision di 0,534, ovvero poco più di metà degli allarmi corrisponde a una giornata effettivamente piovosa. La ROC-AUC è 0,886 e la PR-AUC 0,737, contro un riferimento casuale di 0,223; sulla classe “no pioggia” Precision e Recall valgono rispettivamente 0,94 e 0,80. La matrice di confusione (Figura 3.4) conta 5 134 veri positivi, 1 215 falsi negativi, 4 478 falsi positivi e 17 618 veri negativi.




Figura 3.4: Matrice di confusione, curva ROC e curva Precision-Recall di XGBoost sul test set, configurazione D.

Confronto con le baseline. Rispetto alla persistenza il modello porta l' F_1 da 0,444 a 0,643 e la Recall da 0,441 a 0,809, riducendo il costo atteso da 496,5 a 285,6, cioè del 42%. Rispetto alla regola di maggioranza la riduzione è del 57%. L'accuracy del modello (0,80) supera invece di soli due punti quella della maggioranza (0,78), nonostante le capacità predittive dei due siano incomparabili. È un'ulteriore conferma che su questo problema l'accuracy non misura la qualità della previsione.

Effetto della calibrazione della soglia. Con la soglia di default, invece, il modello della configurazione D avrebbe Recall pari a 0,548, F_1 a 0,631 e costo a 344,9. La soglia calibrata porta la Recall a 0,809 e riduce il costo del 17%, migliorando anche l' F_1 . Il comportamento si ripete in tutte le configurazioni (Tabella 3.11).

Tabella 3.11: Confronto fra soglia di default 0,5 e soglia calibrata sul test set.

Config.	Soglia 0,5			Soglia calibrata		
	F1	Recall	Costo	F1	Recall	Costo
A	0,628	0,545	347,4	0,650	0,779	286,1
B	0,631	0,549	344,5	0,646	0,788	287,5
C	0,628	0,542	347,7	0,642	0,813	285,8
D	0,631	0,548	344,9	0,643	0,809	285,6

3.5 Studio di ablazione

Le sezioni precedenti hanno mostrato i risultati di ogni fase affiancando le quattro configurazioni. Questa sezione li rilegge dal punto di vista delle feature, per rispondere alle domande lasciate aperte dall'EDA. I risultati sono riassunti nella Tabella 3.12, che riporta le sole metriche indipendenti dalla soglia; le metriche dipendenti dalla soglia sono nella Tabella 3.10.

Tabella 3.12: Studio di ablazione. La PR-AUC in CV è riportata sia con i parametri di partenza di XGBoost (confronto dei modelli), usata per la selezione, sia dopo l'ottimizzazione.

Config.	Feature	PR-AUC CV	PR-AUC CV (ott.)	ROC-AUC test	PR-AUC test	Costo
A	135	0,7311 ± 0,0116	0,7340	0,8840	0,7325	286,1
B	133	0,7308 ± 0,0115	0,7337	0,8838	0,7330	287,5
C	137	0,7374 ± 0,0123	0,7417	0,8850	0,7334	285,8
D	133	0,7414 ± 0,0114	0,7443	0,8864	0,7370	285,6

Da A a B: rimozione della ridondanza. La sostituzione di `Rainfall` e `RainToday` con `RainfallLog` lascia le prestazioni invariate ($-0,0003$ di PR-AUC in CV, $+0,0005$ sul test). `RainToday` è una funzione deterministica di `Rainfall`, in quanto un albero ricostruisce da solo la soglia a 1 mm, e la trasformazione logaritmica non altera l'ordinamento dei valori. La permutation importance lo conferma, poiché nella configurazione A `RainToday` ha importanza nulla (Sezione 3.7). La modifica non migliora il modello, ma lo semplifica senza costi.

Da B a C: recupero di `Sunshine` e `Cloud3pm`. È la modifica con l'effetto maggiore in validazione ($+0,0066$ di PR-AUC) e migliora tutti i modelli candidati, non solo XGBoost. Sul test il guadagno si riduce a $+0,0012$ di ROC-AUC e $+0,0004$ di PR-AUC. L'effetto resta contenuto nonostante le due variabili siano fra le più correlate con il target, a causa del fatto che circa metà dei loro valori è imputata, dato che mancano per intere stazioni, e l'informazione che portano è in parte già veicolata da umidità, pressione e pioggia. L'indicatore di mancanza consente comunque al modello di sfruttarle dove sono effettivamente misurate.

Da C a D: riparametrizzazione anti-collinearità. Porta un ulteriore $+0,0040$ di PR-AUC in validazione e il miglior risultato sul test per ROC-AUC (0,8864) e PR-AUC (0,7370), con due variabili numeriche in meno rispetto a C. Poiché per un modello ad albero la collinearità non dovrebbe incidere sulle prestazioni, il guadagno va spiegato altrimenti. Ogni nodo di un albero divide lo spazio lungo un solo asse, per cui una differenza come `MaxTemp - MinTemp` può essere approssimata solo con molte suddivisioni successive; fornendo direttamente l'escursione termica o la tendenza barometrica, la stessa informazione diventa accessibile con una sola suddivisione.

Lettura complessiva. La configurazione D ha la PR-AUC in validazione più alta, sia con i parametri di partenza sia dopo l'ottimizzazione, ed è adottata come modello finale. Il guadagno complessivo rispetto alla configurazione A, circa 1 punto di PR-AUC, è però dello stesso ordine della deviazione standard fra i fold (0,011–0,012). L'ordinamento delle configurazioni è coerente fra modelli diversi e fra validazione e test per le metriche indipendenti dalla soglia, ma le differenze vanno lette come miglioramenti modesti, e in termini operativi

le quattro configurazioni hanno costi attesi equivalenti. L' F_1 sul test, più alto nella configurazione A (Tabella 3.10), non contraddice questa conclusione, perché dipende dalla soglia adottata e non è il criterio di selezione.

3.6 Quantificazione del leakage temporale

Questa sezione rende misurabile il rischio di leakage temporale discusso nell'EDA, confrontando lo split casuale con quello cronologico secondo il procedimento descritto nella Sezione 3.3.5. Come anticipato, il modello di questo confronto è addestrato con le classi ripesate; combinato con una soglia calibrata per il modello non pesato, ciò sposta il punto operativo verso Recall molto alte (circa 0,93–0,95) e F_1 intorno a 0,54. Per questo i valori della Tabella 3.13 vanno letti come differenze fra le due colonne, soprattutto per le metriche indipendenti dalla soglia.

Tabella 3.13: Split casuale con leakage contro split cronologico, a parità di modello e soglia. La colonna Δ indica la sovrastima dovuta allo split casuale, calcolata sui valori non arrotondati.

Config.	Split casuale			Split cronologico			Δ		
	F1	ROC	PR	F1	ROC	PR	F1	ROC	PR
A	0,557	0,893	0,754	0,545	0,883	0,731	+0,011	+0,011	+0,024
B	0,555	0,893	0,754	0,544	0,882	0,731	+0,012	+0,010	+0,023
C	0,552	0,899	0,764	0,535	0,884	0,733	+0,018	+0,015	+0,031
D	0,557	0,901	0,766	0,540	0,887	0,739	+0,017	+0,014	+0,027

In tutte le configurazioni lo split casuale sovrastima le prestazioni di 1–1,5 punti di ROC-AUC e di 2,3–3,1 punti di PR-AUC. La sovrastima è paragonabile, o superiore, all'intero guadagno prodotto dallo studio di ablazione: con una valutazione scorretta si potrebbe credere di aver migliorato il modello quando si è soltanto introdotto leakage.

L'effetto è più marcato nelle configurazioni che includono `Sunshine` e `Cloud3pm`. Una spiegazione plausibile è che insolazione e nuvolosità, persistenti da un giorno all'altro, rendano le giornate adiacenti ancora più simili e quindi più sfruttabili da uno split casuale. Va infine osservato che i due test set non contengono le stesse giornate, per cui il confronto non è controllato in senso stretto, anche se il segno della differenza resta sistematico.

3.7 Importanza delle feature

Dopo aver valutato quanto bene prevede il modello, resta da capire su quali variabili si basa. La Tabella 3.14 riporta la *permutation importance* (Sezione 3.1.5) nelle configurazioni A e D, e la Figura 3.5 la mostra per la configurazione finale.

Dai risultati emergono alcune indicazioni.

- **L'umidità** pomeridiana domina in tutte le configurazioni: permutarla riduce la PR-AUC di 27–31 punti, un effetto da due a quattro volte superiore a quello di ogni altra variabile. Il dato conferma quanto osservato nell'analisi esplorativa, dove `Humidity3pm` mostrava la differenza più netta fra le due classi.
- **Vento e pressione** seguono a distanza, con `WindGustSpeed` e `Pressure3pm` stabilmente al secondo e terzo posto, e `Location` al quarto, a riprova della forte variabilità geografica.

Tabella 3.14: Permutation importance sul test set (calo medio di PR-AUC) nelle configurazioni A e D. Prime dodici variabili.

Configurazione A		Configurazione D	
Variabile	Importanza	Variabile	Importanza
Humidity3pm	0,314	Humidity3pm	0,273
Pressure3pm	0,139	WindGustSpeed	0,070
WindGustSpeed	0,082	Pressure3pm	0,045
Location	0,043	Location	0,039
Pressure9am	0,020	Sunshine	0,022
MinTemp	0,018	PressureTrend	0,020
MaxTemp	0,016	MaxTemp	0,020
Rainfall	0,016	RainfallLog	0,019
Temp3pm	0,016	TempRange	0,013
Humidity9am	0,009	HumidityTrend	0,010
WindSpeed3pm	0,008	Cloud3pm	0,009
WindDir3pm	0,008	WindSpeed3pm	0,007




Figura 3.5: Permutation importance sul test set, configurazione D.

- **Le variabili ridondanti pesano poco o nulla:** nella configurazione A `RainToday` ha importanza 0,000, poiché permutarla non cambia nulla finché `Rainfall` resta nel modello.
- **Le feature recuperate e derivate contribuiscono:** `Sunshine` è la quinta variabile nelle configurazioni C e D, mentre `PressureTrend`, `TempRange` e `HumidityTrend` compaiono fra le prime dieci. Il dato è interessante per `PressureTrend`, la cui correlazione lineare con il target era debole, circa 0,080; il modello ad albero ne sfrutta relazioni non lineari o combinazioni con altre variabili, come ipotizzato nell'EDA.
- **Mese e direzioni del vento** restano marginali, con valori al massimo di 0,008, perché la stagionalità è già catturata indirettamente da temperature e pressione.

L'importanza della pressione cambia molto fra le configurazioni. `Pressure3pm` passa da 0,139 in A a 0,045 in D, dove parte della stessa informazione è espressa da `PressureTrend`. La permutation importance distribuisce infatti il merito fra variabili correlate o derivate l'una dall'altra, per cui i valori non sono additivi e vanno letti come ordinamento più che come quote.

3.7.1 Esempi di inferenza

Per illustrare il funzionamento del modello su casi concreti, esso è stato applicato a otto giornate estratte a caso dal test. Nella configurazione D tutte e otto sono classificate correttamente, con probabilità di pioggia comprese fra 0,004 (Brisbane, 28 luglio 2016) e 0,802 (Penrith, 3 aprile 2017). Una giornata a Salmon Gums del 28 dicembre 2016 riceve probabilità 0,192, appena sotto la soglia 0,20, ed è classificata correttamente come non piovosa; nella configurazione C la stessa giornata riceve 0,209 e diventa un falso allarme. L'esempio mostra quanto le previsioni vicine alla soglia siano sensibili a piccole differenze del modello.

3.8 Conclusioni e limiti

Il problema è stato affrontato con un protocollo che tiene conto sia dello sbilanciamento sia della dipendenza temporale: split cronologico, validazione incrociata temporale con embargo, preprocessing interno alla pipeline, selezione del modello e della configurazione sulla sola validazione e calibrazione della soglia in base ai costi.

XGBoost si conferma il modello migliore in tutte le configurazioni. La configurazione D, che recupera `Sunshine` e `Cloud3pm` e applica la riparametrizzazione anti-collinearità, è la migliore in validazione e ottiene sul test ROC-AUC 0,886, PR-AUC 0,737, Recall 0,809 e F_1 0,643, riducendo del 42% il costo atteso rispetto alla baseline di persistenza.

Quanto alle due domande lasciate aperte dall'EDA, entrambe le modifiche risultano utili. Il recupero di `Sunshine` e `Cloud3pm` migliora tutti i modelli candidati, e la riparametrizzazione porta un ulteriore guadagno pur riducendo il numero di variabili. Le quattro configurazioni restano però vicine fra loro, e i miglioramenti sono dello stesso ordine della variabilità fra i fold.

I limiti dell'analisi, che indicano anche possibili sviluppi, sono i seguenti.

- Gli iperparametri ottimali cadono al bordo della griglia, che andrebbe estesa.
- Lo studio sullo sbilanciamento usa la regressione logistica e un sottoinsieme di 20 000 righe, e SMOTE opera anche sulle variabili *one-hot*.
- MetaCost impiega solo 8 campioni bootstrap e stima le probabilità con tutti i modelli dell'ensemble, anziché con i soli modelli che non hanno visto l'esempio.

- Soglia e iperparametri sono scelti sugli stessi fold di validazione, il che può introdurre un lieve ottimismo nelle stime di validazione; il test set resta comunque intatto.
- Il costo del falso negativo è un'ipotesi di progetto: l'analisi di sensibilità ne mostra l'effetto, ma una taratura su costi reali richiederebbe conoscenza di dominio.
- Il confronto sul leakage usa un modello ripesato, diverso da quello finale, e due test set che non coincidono.

Il clustering è una tecnica di apprendimento non supervisionato che individua strutture nei dati senza ricorrere a etichette predefinite. A differenza della classificazione, dove il modello impara a prevedere un target noto, qui l'algoritmo segmenta le osservazioni in gruppi omogenei sulla base della sola somiglianza fra le loro caratteristiche.

In questo contesto l'obiettivo è verificare se le giornate si aggregano spontaneamente in **regimi meteorologici** ricorrenti, cioè in configurazioni atmosferiche tipiche del territorio australiano. L'interpretazione dei gruppi avviene a posteriori. In particolare, località (`Location`), mese (`Month`) e informazioni sulla pioggia (`RainToday`, `RainTomorrow`) non vengono fornite agli algoritmi e servono soltanto a validare i risultati. La separazione è essenziale, perché se le variabili di validazione partecipassero anche alla costruzione dei cluster la loro corrispondenza con i gruppi sarebbe garantita per costruzione e non proverebbe nulla.

4.1 Strumenti per il clustering

Questa sezione presenta gli strumenti su cui si basa l'analisi. Essi sono la PCA, usata per studiare la ridondanza delle variabili e per visualizzare i dati, i due algoritmi di clustering, K-Means e DBSCAN, gli indici con cui si valuta una partizione e la t-SNE, usata come controllo visivo.

4.1.1 Analisi delle componenti principali

La **Principal Component Analysis** (PCA) proietta i dati in un nuovo sistema di coordinate, le *componenti principali*, ortogonali fra loro e ordinate per varianza spiegata decrescente. Ogni componente è una combinazione lineare delle variabili originali, e i coefficienti della combinazione (*loadings*) indicano quanto ciascuna variabile contribuisce alla componente.

Nell'analisi la PCA ha due scopi. Il primo è quantificare la ridondanza contenuta nelle variabili: se poche componenti spiegano gran parte della varianza, le variabili originali portano informazione in buona parte sovrapposta. Il secondo è fornire due dimensioni su cui visualizzare i cluster. Gli algoritmi di clustering operano invece sempre nello spazio completo delle variabili standardizzate, e non sulla proiezione.

4.1.2 K-Means

K-Means suddivide le n osservazioni in k gruppi non sovrapposti $C_1, \dots, C_k$, ciascuno rappresentato dal proprio centroide μ_j , cioè dalla media dei punti che gli appartengono. L'algoritmo minimizza l'**inerzia**, ovvero la somma delle distanze quadratiche dei punti dal centroide del proprio gruppo:

$$W_k = \sum_{j=1}^k \sum_{x_i \in C_j} \|x_i - \mu_j\|^2. \quad (4.1)$$

Il procedimento alterna due passi, l'assegnazione di ogni punto al centroide più vicino e il ricalcolo dei centroidi, fino a convergenza. Poiché il risultato dipende dall'inizializzazione, l'algoritmo viene eseguito più volte con centroidi iniziali diversi e si conserva la soluzione con inerzia minore.

K-Means presenta due caratteristiche rilevanti per questo lavoro. Il numero di gruppi k va fissato a priori, e la sua scelta richiede criteri esterni all'algoritmo. Inoltre, K-Means assegna ogni punto a un gruppo anche quando i dati non presentano separazioni nette; in particolare, partiziona lo spazio in regioni contigue anziché cercare zone isolate.

4.1.3 DBSCAN

DBSCAN (*Density-Based Spatial Clustering of Applications with Noise*) definisce i cluster come regioni ad alta densità separate da regioni rare. A differenza di K-Means non richiede di fissare il numero di gruppi, può individuare cluster di forma arbitraria ed etichetta esplicitamente i punti che non appartengono ad alcun gruppo come **rumore**.

L'algoritmo dipende da due parametri: il raggio di vicinato ε e il numero minimo di punti `min_samples`. In base a questi, ogni osservazione ricade in una di tre categorie:

- **core points**: ha almeno `min_samples` punti entro distanza ε ;
- **border points**: non è core, ma si trova entro distanza ε da un punto core;
- **rumore**: non soddisfa nessuna delle due condizioni.

Un cluster è formato dai punti core collegati fra loro attraverso vicini sovrapposti, insieme ai relativi punti di bordo.

Il raggio ε si tara di norma con il **k-distance plot**, ovvero per ogni punto si calcola la distanza dal suo `min_samples`-esimo vicino e si ordinano le distanze in senso crescente. Se i dati contengono cluster ben separati, la curva presenta un ginocchio, in cui le distanze che lo precedono corrispondono a punti interni ai cluster, quelle che lo seguono a punti di rumore. Il valore di ε si sceglie in corrispondenza del ginocchio.

4.1.4 Indici di valutazione interni

Gli indici interni valutano una partizione usando solo i dati su cui è stata costruita, e misurano quanto i gruppi sono compatti al loro interno e separati fra loro.

- **Inerzia** W_k : decresce sempre all'aumentare di k . Nel *metodo del gomito* si cerca il valore oltre il quale la riduzione diventa marginale.
- **Silhouette**: per ogni punto i si calcolano la distanza media $a(i)$ dai punti del proprio cluster e la distanza media $b(i)$ dai punti del cluster più vicino, e si definisce

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}. \quad (4.2)$$

L'indice è la media di $s(i)$ e varia fra -1 e 1 . Valori vicini a 1 indicano gruppi compatti e ben separati; valori intorno a 0 indicano punti a cavallo fra due gruppi. Valori sotto $0,25$ sono di solito interpretati come struttura debole.

- **Indice di Davies-Bouldin:** media, su tutti i cluster, del rapporto fra la dispersione interna di un cluster e la sua distanza dal cluster più simile. Va minimizzato.
- **Indice di Calinski-Harabasz:** rapporto fra la varianza fra i cluster e la varianza entro i cluster, corretto per il numero di gruppi e di punti. Va massimizzato.

4.1.5 Indici di valutazione esterni

Gli indici esterni confrontano la partizione con un'etichetta nota che non ha partecipato alla sua costruzione, come la stagione o la pioggia del giorno successivo.

- **Adjusted Rand Index (ARI):** considera tutte le coppie di osservazioni e misura quanto spesso le due partizioni concordano nel metterle nello stesso gruppo o in gruppi diversi, con una correzione che rende nullo il valore atteso per un'assegnazione casuale. Vale 1 per partizioni identiche e circa 0 per corrispondenza casuale.
- **Homogeneity:** vale 1 se ogni cluster contiene osservazioni di una sola classe dell'etichetta esterna.
- **Completeness:** vale 1 se tutte le osservazioni di una stessa classe finiscono nello stesso cluster.
- **V-measure:** media armonica di homogeneity e completeness, compresa fra 0 e 1 .

Homogeneity e completeness sono utili letti insieme, perché distinguono cluster "puri" che però spezzano una classe in più gruppi, oppure classi raccolte in pochi cluster che però ne mescolano molte.

4.1.6 t-SNE

La PCA è una proiezione lineare, e una struttura non lineare nei dati potrebbe non essere visibile sul suo piano. La **t-SNE** (*t-distributed Stochastic Neighbor Embedding*) è una tecnica di visualizzazione non lineare che cerca una rappresentazione in due dimensioni in cui i punti vicini nello spazio originale restino vicini. Il parametro di *perplexità* corrisponde approssimativamente al numero di vicini considerati per ogni punto. La t-SNE preserva la struttura locale ma non le distanze globali, in quanto la distanza fra due gruppi lontani nella mappa non ha un significato quantitativo. Ha inoltre un costo quadratico nel numero di punti.

4.2 Preprocessing dei dati

Gli algoritmi basati su distanze impongono requisiti precisi sui dati: le osservazioni devono essere complete, le variabili devono avere scale confrontabili e i valori estremi non devono dominare il calcolo delle distanze. Le operazioni di questa sezione rispondono a questi requisiti.

4.2.1 Selezione delle feature

Si parte dal dataset completo (145 460 righe) e si scartano le quattro colonne a mancanza strutturale (*Sunshine*, *Evaporation*, *Cloud9am*, *Cloud3pm*). Gli algoritmi basati su distanze richiedono infatti osservazioni complete, e imputare intere colonne per le stazioni prive dello strumento equivarrebbe a costruire punti artificiali su cui poi calcolare la geometria dello spazio.

Restano 12 variabili meteorologiche continue:

- **temperature:** *MinTemp*, *MaxTemp*, *Temp9am*, *Temp3pm*;
- **precipitazione:** *Rainfall*;
- **vento:** *WindGustSpeed*, *WindSpeed9am*, *WindSpeed3pm*;
- **umidità:** *Humidity9am*, *Humidity3pm*;
- **pressione:** *Pressure9am*, *Pressure3pm*.

Le direzioni del vento non sono incluse perché, essendo categoriche a 16 modalità disposte su una circonferenza, non ammettono una distanza naturale compatibile con K-Means. Mantenendo solo le righe complete su queste variabili restano 120 381 osservazioni. Poiché il target non viene usato, non è necessario eliminare le righe prive di *RainTomorrow*. Cinque località, invece, spariscono del tutto per assenza di dati completi (*Albany*, *MountGinini*, *Newcastle*, *Penrith* e *SalmonGums*), per cui l'analisi riguarda 44 stazioni.

4.2.2 Campionamento

Da queste osservazioni viene estratto un campione casuale di 10 000 giornate. La scelta è dettata dal costo computazionale, in quanto *Silhouette*, *DBSCAN* e *t-SNE* hanno complessità quadratica nel numero di punti, e su 120 381 osservazioni i tempi diventerebbero proibitivi.

Il campionamento casuale, che nella classificazione avrebbe introdotto leakage, qui è legittimo. Il clustering descrive la struttura dei dati e non prevede il futuro, quindi l'ordine temporale non ha alcun ruolo nel risultato. Il confronto con l'insieme completo delle 120 381 osservazioni conferma la rappresentatività del campione. Le medie delle dodici variabili differiscono di meno dell'1% e le mediane di al più 0,1 unità; fa eccezione la media della pioggia (2,4 contro 2,3 mm), sensibile ai pochi valori estremi, mentre la mediana è nulla in entrambi.

4.2.3 Trasformazione e standardizzazione

Come mostrato nell'EDA, *Rainfall* è fortemente asimmetrica. Senza correzione i pochi giorni con precipitazioni estreme dominerebbero il calcolo delle distanze, spostando i centroidi verso valori non rappresentativi. Viene quindi applicata la trasformazione $\log(1 + x)$, che comprime la coda destra, conserva l'ordinamento dei valori e lascia invariati gli zeri.

Tutte le variabili vengono poi standardizzate a media nulla e varianza unitaria. Questo passaggio è necessario perché le grandezze hanno unità di misura e intervalli molto diversi, infatti senza standardizzazione la pressione, dell'ordine di 1000 hPa, dominerebbe il calcolo della distanza euclidea rispetto all'umidità o alle velocità del vento, rendendo queste ultime di fatto irrilevanti.

Anche dopo la standardizzazione i valori massimi restano molto diversi fra le variabili, si passa da 1,66 deviazioni standard per *Humidity9am*, che ha un tetto fisico al 100%, a 7,75 per *WindSpeed3pm*. Le variabili di vento conservano cioè code lunghe, aspetto che si ritroverà nell'analisi degli outlier.

4.3 Protocollo sperimentale

Un'analisi di clustering richiede di stabilire tre cose prima di guardare i risultati: come scegliere i parametri degli algoritmi, come confrontare le soluzioni ottenute e come verificare che i gruppi abbiano un significato. Le sottosezioni seguenti descrivono le scelte adottate per ciascun aspetto.

4.3.1 Scelta del numero di cluster

K-Means viene eseguito per k da 2 a 8, con 10 inizializzazioni per ciascun valore. Per ogni partizione si calcolano gli indici interni della Sezione 4.1.4; la Silhouette è calcolata su un sottocampione di 5 000 punti per contenerne il costo quadratico.

Gli indici interni misurano però solo compattezza e separazione, e con dati che non formano gruppi nettamente distinti tendono a favorire le partizioni più grossolane. Non dicono se una partizione sia informativa o riproducibile. Per i valori candidati $k \in \{2, 3, 4, 5\}$ si calcolano quindi quattro criteri aggiuntivi:

- **Varianza spiegata**, pari a $1 - W_k/W_1$, dove W_1 è l'inerzia di un unico cluster, che indica quanta parte della variabilità dei dati è catturata dalla partizione;
- **Stabilità**: K-Means viene ripetuto su 10 sottocampioni casuali pari all'80% dei dati, e per ciascuno si calcola l'ARI fra la nuova partizione e quella originale sugli stessi punti. Si riportano media e deviazione standard. Una partizione stabile deve riprodursi indipendentemente dal campione;
- **Riducibilità a una variabile**: il massimo ARI fra la partizione e una suddivisione in k quantili di una singola variabile. Un valore alto indica che il clustering si limita a tagliare una sola grandezza, senza cogliere struttura multivariata;
- **Distanza minima fra i centroidi** nello spazio standardizzato, che indica quanto sono distinti i due gruppi più vicini.

Per la scelta finale si adotta il valore di k più grande per cui la partizione resta stabile, cioè con ARI medio elevato e bassa dispersione fra i sottocampioni, e non è riducibile a una singola variabile. In questo modo si cattura la maggiore quantità di struttura che i dati sostengono in modo riproducibile.

Nella stessa fase si calcolano anche l'ARI e la V-measure rispetto alla stagione australe (estate tra dicembre–febbraio, autunno tra marzo–maggio, inverno tra giugno–agosto, primavera tra settembre–novembre). Questi valori sono riportati a titolo informativo e **non** entrano nella scelta di k , che si basa solo su informazioni interne ai dati.

4.3.2 Scelta parametri di DBSCAN

Per DBSCAN il parametro `min_samples` è fissato a 24, secondo la regola pratica che lo pone pari al doppio della dimensionalità dello spazio (2×12). Il raggio ϵ viene cercato con il k-distance plot. Se la curva non presenta un ginocchio riconoscibile, anziché scegliere un valore arbitrario si esplora una griglia di raggi (1,0; 1,2; 1,5; 1,8; 2,0; 2,5; 3,0), riportando per ciascuno il numero di cluster, la quota di rumore e la dimensione del cluster più grande.

Se nessun valore produce una partizione utilizzabile, DBSCAN viene impiegato come **rilevatore di anomalie**, ovvero fra i valori della griglia si adotta quello che lascia un nucleo maggioritario isolando una quota non marginale di punti, e si studia il profilo delle giornate classificate come rumore.

4.3.3 Confronto fra gli algoritmi

Le soluzioni di K-Means e DBSCAN sono confrontate con gli indici interni, quando calcolabili; con una tabella di contingenza fra i cluster di K-Means e gli outlier di DBSCAN, per verificare se i due algoritmi individuano le stesse giornate atipiche; con un confronto visivo sulla proiezione t-SNE. Quest'ultima è calcolata su un sottocampione di 3 000 punti, con perplessità 30 e inizializzazione da PCA, per escludere che l'assenza di separazione osservata sul piano della PCA sia un effetto della sua linearità.

4.3.4 Interpretazione e validazione a posteriori

I cluster della soluzione adottata vengono prima descritti attraverso i valori medi delle variabili, in unità originali e come scostamento standardizzato dalla media globale, così da attribuire a ciascuno un significato meteorologico.

Vengono poi incrociati con le variabili escluse dall'apprendimento:

- **pioggia:** frequenza di `RainTomorrow` e `RainToday` per cluster. La corrispondenza con `RainToday` è in parte attesa, perché la quantità di pioggia del giorno è una delle feature; quella con `RainTomorrow` costituisce una validazione più indipendente;
- **stagionalità:** distribuzione dei mesi all'interno di ciascun cluster;
- **località:** località più rappresentate in ogni cluster e cluster dominante per stazione, cioè quello che raccoglie la maggior parte delle sue giornate nel campione. Le stazioni sono proiettate su una mappa schematica dell'Australia con coordinate approssimate, affiancata dalla frequenza reale di pioggia.

La corrispondenza con stagione, pioggia del giorno successivo e località è infine quantificata con gli indici esterni della Sezione 4.1.5.

4.4 Risultati

I risultati sono presentati nell'ordine del protocollo: prima la struttura dei dati vista attraverso la PCA, poi la scelta di k e la partizione di K-Means, quindi DBSCAN e il confronto fra i due algoritmi, e infine l'interpretazione e la validazione dei regimi individuati.

4.4.1 Struttura dei dati

La prima componente principale spiega il 39,5% della varianza e la seconda il 22,1%, per un totale del 61,5% su due sole dimensioni (Figura 4.1); per superare l'80% servono 4 componenti. Le variabili contengono quindi molta informazione ridondante, coerentemente con la multicollinearità misurata nell'EDA (Sezione 2.6).

I coefficienti riportati nella Tabella 4.1 permettono di attribuire un significato fisico alle due componenti.

- **PC1 è un asse termico:** presenta pesi positivi elevati e simili sulle quattro temperature (0,37–0,41) e pesi negativi su pressione e umidità del mattino. Valori alti corrispondono a giornate calde, con pressione più bassa e aria più secca.
- **PC2 è un asse della perturbazione:** ha pesi positivi su vento, pioggia e umidità pomeridiana e pesi negativi sulle pressioni. Valori alti corrispondono a giornate ventose, umide e piovose con pressione bassa, tipiche del passaggio di un sistema perturbato.




Figura 4.1: Varianza spiegata da ciascuna componente (sinistra) e varianza cumulata (destra).

Tabella 4.1: Coefficienti delle variabili sulle prime due componenti principali (*loadings*).

Variabile	PC1	PC2
MinTemp	0,37	0,04
MaxTemp	0,41	−0,23
Rainfall (log)	−0,04	0,36
WindGustSpeed	0,19	0,41
WindSpeed9am	0,14	0,32
WindSpeed3pm	0,15	0,37
Humidity9am	−0,28	0,21
Humidity3pm	−0,19	0,34
Pressure9am	−0,29	−0,32
Pressure3pm	−0,31	−0,26
Temp9am	0,41	−0,09
Temp3pm	0,40	−0,26

Il piano delle prime due componenti è usato per tutte le visualizzazioni successive. Va però ricordato che rappresenta il 61,5% della varianza, quindi gruppi che appaiono sovrapposti nel piano possono risultare separati nelle dimensioni restanti.

4.4.2 Scelta del numero di cluster

La Tabella 4.2 e la Figura 4.2 riportano gli indici interni al variare di k . Nessun indice interno seleziona $k = 4$. Silhouette e Calinski-Harabasz sono massimi a $k = 2$, Davies-Bouldin è minimo a $k = 3$, e la Silhouette cala nettamente da $k = 3$ (0,226) a $k = 4$ (0,161) per poi restare quasi costante. L'inerzia decresce in modo regolare senza un gomito riconoscibile. Presi alla lettera, gli indici indicherebbero $k = 2$ oppure $k = 3$. Anche ARI e V-measure rispetto alla stagione, riportati a titolo informativo, sono massimi a $k = 2$.

Tabella 4.2: Indici di valutazione di K-Means al variare di k . In grassetto l'ottimo di ciascun indice interno. Le ultime due colonne, rispetto alla stagione, sono riportate a titolo informativo e non entrano nella scelta di k .

k	Inerzia	Silhouette	Davies-B.	Calinski-H.	ARI stag.	V-meas.
2	88 685	0,230	1,591	3 530,4	0,120	0,129
3	74 788	0,226	1,572	3 021,8	0,097	0,098
4	67 897	0,161	1,648	2 556,9	0,093	0,114
5	62 527	0,160	1,599	2 296,8	0,087	0,115
6	58 368	0,162	1,654	2 110,6	0,079	0,104
7	55 531	0,159	1,619	1 933,6	0,078	0,109
8	53 080	0,152	1,610	1 799,6	0,069	0,103




Figura 4.2: Metodo del gomito, Silhouette e ARI rispetto alla stagione al variare di k .

I criteri aggiuntivi della Tabella 4.3 consentono di andare oltre la sola compattezza.

Tabella 4.3: Criteri aggiuntivi per la scelta di k .

k	Var. spiegata	Stabilità (ARI)	Dev. std	Riducibilità	Dist. min. centroidi
2	0,261	0,993	0,004	0,522	3,545
3	0,377	0,985	0,005	0,347	3,454
4	0,434	0,980	0,006	0,337	2,746
5	0,479	0,865	0,161	0,251	2,675

Con $k = 2$ la partizione è quasi banale. La riducibilità di 0,522 indica che oltre metà del risultato si ottiene dividendo in due una sola variabile, infatti l'algoritmo separa le giornate

calde da quelle fredde e cattura appena il 26% della varianza. Con $k = 3$ la riducibilità scende a 0,347 e la varianza spiegata sale al 38%, con stabilità ancora altissima (0,985). Con $k = 4$ la varianza spiegata raggiunge il 43% e la riducibilità cala ancora, seppure di poco (0,337), senza che la stabilità peggiori in modo apprezzabile ($0,980 \pm 0,006$). Con $k = 5$, infine, la stabilità crolla a 0,865 con deviazione standard 0,161, oltre venti volte maggiore. Su alcuni sottocampioni la quinta suddivisione cambia in modo sostanziale e non è quindi riproducibile.

Applicando la regola del protocollo si adotta quindi $k = 4$, il massimo numero di cluster che i dati sostengono in modo stabile.

La Silhouette di 0,161 merita un commento, dato che un valore inferiore a 0,25 indicherebbe in genere una struttura debole. Nel caso in esame il risultato riflette la natura del fenomeno più che un fallimento dell'algoritmo. In particolare, le condizioni meteorologiche formano un continuo e non gruppi separati da regioni vuote, mentre la Silhouette premia proprio la separazione netta. È la stessa proprietà che, come si vedrà, rende inadatto DBSCAN.

4.4.3 Partizione di K-Means

Con $k = 4$ i cluster contengono rispettivamente 2 427, 3 239, 2 409 e 1 925 giornate, e nessun gruppo risulta marginale. La proiezione sulle prime due componenti (Figura 4.3) mostra tre cluster disposti lungo l'asse termico, dal freddo al caldo, e un quarto separato lungo l'asse della perturbazione. I confini fra i gruppi sono contigui, senza spazi vuoti.



Figura 4.3: Cluster K-Means ($k = 4$) e relativi centroidi proiettati sulle prime due componenti principali.

4.4.4 DBSCAN

Sensibilità al raggio. Il k-distance plot (Figura 4.4) cresce in modo graduale, senza un ginocchio riconoscibile, per cui si è esplorata la griglia di raggi prevista dal protocollo,

rappresentata in Tabella 4.4.




Figura 4.4: k-distance plot con `min_samples = 24`. Le linee tratteggiate indicano il 50°, il 90° e il 95° percentile delle distanze.

Tabella 4.4: Analisi di sensibilità di DBSCAN al raggio ε , con `min_samples = 24`.

ε	N. cluster	N. outlier	% outlier	Cluster più grande
1,0	3	8 752	87,5%	1 194
1,2	1	5 073	50,7%	4 927
1,5	1	1 953	19,5%	8 047
1,8	1	636	6,4%	9 364
2,0	1	343	3,4%	9 657
2,5	1	57	0,6%	9 943
3,0	1	11	0,1%	9 989

Nessun valore di ε produce un clustering utilizzabile. Con $\varepsilon = 1,0$ si ottengono tre piccoli cluster, ma l'87,5% dei punti è rumore; già a $\varepsilon = 1,2$ resta un solo cluster, che al crescere del raggio assorbe progressivamente tutti i punti. Si passa cioè da una situazione in cui quasi tutto è rumore a una in cui tutto appartiene a un unico gruppo, senza alcun regime intermedio.

Il motivo è strutturale. Le condizioni meteorologiche standardizzate formano una nuvola continua, priva di discontinuità di densità fra un tipo di giornata e l'altro. La dimensionalità aggrava il problema, perché in 12 dimensioni le distanze fra i punti tendono a concentrarsi su valori simili e la nozione di vicinato perde potere discriminante. Il risultato negativo è comunque informativo, perché documenta una proprietà dei dati e giustifica l'adozione di K-Means, che partiziona lo spazio senza richiedere regioni vuote fra i gruppi. Per lo stesso motivo gli indici interni di DBSCAN non sono calcolabili in quanto richiedono almeno due cluster, mentre l'algoritmo ne produce uno solo.

DBSCAN come rilevatore di anomalie. Secondo il protocollo si adotta $\varepsilon = 1,5$, l'unico valore della griglia che lascia un nucleo ampio, di 8 047 giornate, isolando una quota non marginale di punti, ovvero 1 953, pari al 19,5% (Figura 4.5). Pur non costituendo una partizione, il risultato è utile, perché gli outlier hanno un profilo nettamente riconoscibile (Tabella 4.5).

Si tratta di giornate perturbate in cui le raffiche sono mediamente più forti di 17,5 km/h, la pioggia media è di 9,3 mm contro 0,7 mm, l'umidità è più alta e la pressione più bassa di 6–7 hPa, mentre le temperature differiscono poco dal nucleo. La validazione con i dati sulla




Figura 4.5: Risultato di DBSCAN ($\varepsilon = 1,5$) proiettato sulle prime due componenti principali, con gli outlier in rosso.

Tabella 4.5: Profilo medio delle giornate classificate come outlier da DBSCAN ($\varepsilon = 1,5$) rispetto al nucleo, ordinato per scarto assoluto.

Variabile	Outlier ($n = 1\,953$)	Nucleo ($n = 8\,047$)	Scarto
WindGustSpeed (km/h)	54,2	36,7	+17,5
Humidity3pm (%)	61,1	48,5	+12,6
Rainfall (mm)	9,3	0,7	+8,6
Pressure9am (hPa)	1 012,1	1 018,9	−6,8
WindSpeed3pm (km/h)	24,4	17,8	+6,6
WindSpeed9am (km/h)	19,5	13,0	+6,5
Humidity9am (%)	73,4	67,2	+6,2
Pressure3pm (hPa)	1 010,4	1 016,3	−5,9
Temp3pm (°C)	19,9	22,5	−2,6
MaxTemp (°C)	21,9	23,9	−2,0
MinTemp (°C)	13,2	12,2	+1,0
Temp9am (°C)	16,8	17,3	−0,5

pioggia, che l'algoritmo non ha mai visto, conferma che fra gli outlier piove il giorno stesso nel 60,5% dei casi contro il 13,0% del nucleo, e il giorno successivo nel 49,2% contro il 15,2%.

Confronto con K-Means. Il profilo degli outlier ricorda da vicino quello di uno dei cluster K-Means, e la tabella di contingenza fra le due soluzioni lo conferma (Tabella 4.6). Il cluster 3 raccoglie il 61,8% di tutti gli outlier, e il 62,7% delle sue giornate risulta anomalo per DBSCAN, contro un tasso medio del 19,5%: un fattore 3,2. La sovrapposizione è però parziale, dato che circa un quinto degli outlier appartiene al cluster 2, quello delle giornate più calde.

Tabella 4.6: Giornate classificate come outlier da DBSCAN in ciascun cluster K-Means.

Cluster K-Means	Nucleo	Outlier	% outlier nel cluster	Quota degli outlier
0	2 214	213	8,8%	10,9%
1	3 107	132	4,1%	6,8%
2	2 008	401	16,6%	20,5%
3	718	1 207	62,7%	61,8%

I due algoritmi colgono nozioni diverse di atipicità. K-Means individua la struttura ricorrente dei dati, DBSCAN la deviazione dalla densità locale. La loro convergenza parziale è essa stessa un risultato, perché identifica il regime perturbato come una regione a bassa densità dello spazio delle feature.

4.4.5 Confronto visivo con t-SNE

Anche nella proiezione t-SNE (Figura 4.6) i dati formano un'unica massa continua, priva di isole separate. K-Means la suddivide in quattro regioni contigue, mentre DBSCAN la considera un unico gruppo con gli outlier distribuiti sui margini. L'assenza di separazione non dipende quindi dalla linearità della PCA, ma è una proprietà dei dati.




Figura 4.6: Proiezione t-SNE di 3000 giornate colorate secondo K-Means (sinistra) e DBSCAN (destra).

4.4.6 Interpretazione dei regimi

La Tabella 4.7 riporta i profili medi dei quattro cluster in unità originali, mentre la Figura 4.7 mostra gli scostamenti dalla media globale in deviazioni standard. Nella mappa di calore la pioggia compare in scala logaritmica, coerentemente con la trasformazione applicata prima del clustering; i valori in millimetri sono quelli della tabella.

Tabella 4.7: Valori medi delle variabili per i quattro cluster K-Means, in unità di misura originali.

Variabile	Cluster 0	Cluster 1	Cluster 2	Cluster 3
N. giornate	2 427	3 239	2 409	1 925
MinTemp (°C)	6,0	12,2	19,3	12,2
MaxTemp (°C)	16,8	24,4	32,5	19,1
Temp9am (°C)	10,3	17,6	25,2	15,1
Temp3pm (°C)	15,8	23,0	30,7	17,3
Rainfall (mm)	1,3	0,4	1,2	8,6
WindGustSpeed (km/h)	30,4	36,1	43,8	54,4
WindSpeed9am (km/h)	9,3	12,5	15,9	21,6
WindSpeed3pm (km/h)	14,0	17,1	21,0	26,3
Humidity9am (%)	82,0	63,4	54,5	77,1
Humidity3pm (%)	58,1	45,1	39,0	66,6
Pressure9am (hPa)	1 024,3	1 019,3	1 012,8	1 012,1
Pressure3pm (hPa)	1 022,0	1 016,6	1 009,7	1 010,9




Figura 4.7: Profilo standardizzato dei cluster K-Means, come scostamento di ogni variabile dalla media globale.

Incrociando i valori medi con i tre scostamenti standardizzati più ampi di ciascun gruppo si ottengono quattro regimi riconoscibili.

1. **Cluster 0, regime freddo e stabile.** Presenta le temperature più basse (minima 6,0 °C, massima 16,8 °C), la pressione più alta (1 022,0 hPa alle 15:00), venti deboli e umidità mattutina elevata (82%). I tratti distintivi sono Temp9am (−1,07 deviazioni standard),

MinTemp ($-1,01$) e Pressure3pm ($+0,98$). È la configurazione tipica dell’anticiclone invernale, con notti fredde e cielo stabile.

2. **Cluster 1, regime mite e secco.** È il gruppo più numeroso, con temperature intermedie (massima $24,4^{\circ}\text{C}$), la pioggia media più bassa ($0,4$ mm) e venti moderati. Si caratterizza per l’assenza di estremi: gli scostamenti più ampi sono tutti negativi e contenuti, su pioggia ($-0,36$), raffiche ($-0,30$) e umidità pomeridiana ($-0,28$). Corrisponde alle giornate calme e asciutte.
3. **Cluster 2, regime caldo.** Ha le temperature più alte (massima $32,5^{\circ}\text{C}$), l’umidità pomeridiana più bassa (39%) e pressione bassa ($1\,009,7$ hPa alle 15:00). I tratti distintivi sono tutti termici: MaxTemp ($+1,29$), Temp3pm ($+1,27$) e Temp9am ($+1,25$). Comprende sia le giornate estive delle regioni temperate sia quelle delle stazioni tropicali e dell’entroterra arido.
4. **Cluster 3, regime perturbato e ventoso.** Registra le raffiche più forti ($54,4$ km/h), la pioggia media più alta ($8,6$ mm), l’umidità pomeridiana più elevata ($66,6\%$) e la pressione più bassa al mattino ($1\,012,1$ hPa). I tratti distintivi sono WindGustSpeed ($+1,05$), pioggia ($+1,02$) e WindSpeed9am ($+0,83$), coerenti con il passaggio di sistemi perturbati.

4.4.7 Validazione con variabili esterne

I quattro regimi sono infine confrontati con le variabili che non hanno partecipato all’apprendimento, come previsto dalla Sezione 4.3.4.




Figura 4.8: (a) Percentuale di giornate seguite da pioggia per cluster, con la media globale del 22%. (b) Distribuzione dei mesi all’interno di ciascun cluster.

Pioggia. La frequenza di pioggia il giorno successivo varia fortemente fra i gruppi (Figura 4.8a). Nel cluster 3 supera il 50%, più del doppio della media globale del 22%, mentre negli altri tre resta sotto la media, con il minimo nel cluster 1 (circa 11%) e valori intorno al 16–17% nei cluster 0 e 2. Sulla pioggia del giorno stesso l’ordinamento è ancora più netto (Tabella 4.8): 60,4% nel cluster 3 contro 7,8% nel cluster 1. L’algoritmo ha quindi isolato le condizioni di instabilità senza aver mai visto la pioggia come etichetta. Come anticipato nel protocollo, la corrispondenza con RainToday è in parte attesa, mentre quella con RainTomorrow costituisce una validazione più indipendente.

Tabella 4.8: Percentuale di giornate con pioggia nel giorno stesso (*RainToday*) per cluster.

	Cluster 0	Cluster 1	Cluster 2	Cluster 3
Pioggia oggi	21,4%	7,8%	12,1%	60,4%

Stagionalità. La distribuzione dei mesi (Figura 4.8b) è coerente con le stagioni australi. Il cluster freddo si concentra fra maggio e agosto, con il massimo a giugno, ed è quasi assente in estate; il cluster caldo si concentra fra dicembre e febbraio, con il massimo a gennaio, ed è quasi assente in inverno. Il cluster mite è più frequente nelle stagioni di transizione, in particolare a marzo e fra ottobre e novembre. Il cluster perturbato è invece distribuito in modo relativamente uniforme lungo tutto l’anno, con una frequenza leggermente più alta fra fine inverno e inizio primavera: le perturbazioni non appartengono a una sola stagione.

Indici quantitativi. I valori della Tabella 4.9 sono bassi, come atteso. I regimi meteorologici attraversano stagioni e località senza coincidere con esse: una stessa stazione vive giornate fredde, miti e perturbate, e una stessa stagione contiene regimi diversi. La corrispondenza più alta è con la stagione, coerentemente con il ruolo dominante della temperatura nella partizione. Per *RainTomorrow* l’homogeneity (0,110) è molto più alta della completeness (0,042): alcuni cluster sono quasi puri rispetto alla pioggia, come il cluster 1 per le giornate asciutte, ma la pioggia è distribuita su più gruppi. Per la località vale il contrario (completeness 0,128 contro homogeneity 0,047), poiché le giornate di una stessa stazione tendono a concentrarsi in pochi cluster, mentre ogni cluster mescola molte stazioni.

Tabella 4.9: Indici di corrispondenza fra la partizione K-Means ($k = 4$) ed etichette esterne, dove 0 indica corrispondenza casuale e 1 coincidenza perfetta.

Etichetta esterna	ARI	V-measure	Homogeneity	Completeness
Stagione	0,093	0,114	0,113	0,114
<i>RainTomorrow</i>	0,055	0,061	0,110	0,042
Località	0,014	0,068	0,047	0,128

Distribuzione geografica. La Figura 4.9 mostra il cluster dominante di ciascuna delle 44 stazioni, affiancato dalla frequenza reale di pioggia. La corrispondenza con la climatologia australiana è buona.

- **Nord tropicale ed entroterra:** domina il regime caldo, da Darwin, Katherine, Cairns e Townsville fino ad Alice Springs, Uluru, Woomera, Cobar e Moree, oltre che a Perth. Le località più rappresentate nel cluster sono Darwin (11% delle giornate del cluster), Cairns (8%) e Townsville (6%). Il gruppo riunisce climi molto diversi per piovosità, caldi e umidi al nord e caldi e aridi nell’interno, accomunati dalle temperature elevate.
- **Costa orientale e isole:** prevale il regime mite e secco, da Brisbane a Coffs Harbour fino all’area di Sydney e a Norfolk Island, oltre che in parte del sud-ovest. Le località più rappresentate sono Brisbane, Norfolk Island e Adelaide.
- **Sud-est interno e Tasmania settentrionale:** domina il regime freddo e stabile, da Canberra all’area di Melbourne fino a Launceston, con Watsonia, Ballarat e Albury al 4% ciascuna.




Figura 4.9: A sinistra il cluster K-Means dominante per stazione, a destra la percentuale di giornate seguite da pioggia.

- **Stazioni meridionali più esposte:** prevale il regime perturbato, come a Mount Gambier e Hobart; le località più rappresentate nel cluster sono Ballarat, Norfolk Island e Hobart (5% ciascuna).

Il confronto con il pannello destro mostra che le stazioni dell'entroterra dominate dal regime caldo sono fra le meno piovose, sotto il 10%, mentre le frequenze più alte si trovano lungo le coste meridionali e sud-occidentali. Il cluster dominante non spiega però da solo la piovosità, in quanto Cairns, dominata dal regime caldo, è al tempo stesso fra le stazioni più piovose, perché il clima tropicale umido combina temperature elevate e precipitazioni frequenti. Le percentuali di località vanno infine lette come quote delle giornate del cluster, per cui le stazioni con più osservazioni nel campione pesano di più.

4.5 Conclusioni e limiti

Il clustering ha individuato quattro regimi meteorologici interpretabili (freddo e stabile, mite e secco, caldo, perturbato e ventoso), coerenti con stagioni, piovosità e geografia pur senza aver usato queste informazioni nella fase di apprendimento.

La scelta di $k = 4$ non deriva dagli indici interni, che preferirebbero $k = 2$ o $k = 3$, ma da criteri dichiarati nel protocollo. Si ottiene una varianza spiegata quasi doppia rispetto a $k = 2$, una partizione non riducibile a una singola variabile e la massima stabilità prima del crollo osservato a $k = 5$. L'interpretabilità meteorologica dei quattro gruppi, emersa solo a posteriori, conferma la scelta. DBSCAN fallisce invece come algoritmo di partizionamento, poiché i dati formano un continuo privo di discontinuità di densità; resta però utile come rilevatore di anomalie, dato che le giornate isolate corrispondono in larga parte al regime perturbato individuato da K-Means.

I valori bassi di Silhouette e degli indici esterni non indicano un fallimento, ma riflettono la natura del fenomeno, perché i regimi meteorologici sono una segmentazione utile di un continuo, non gruppi naturalmente separati.

I principali limiti dell'analisi sono i seguenti.

- Il clustering opera su un campione di 10 000 giornate e non sull'intero insieme di 120 381 osservazioni complete.
- Cinque stazioni sono escluse per assenza di dati completi, e le variabili a mancanza strutturale, fra cui insolazione e nuvolosità, non vengono usate.

- La soglia di stabilità usata per scegliere k è qualitativa: il crollo a $k = 5$ è netto, ma una soglia numerica fissata in anticipo renderebbe la regola più rigorosa.
- La mappa impiega coordinate approssimate e il solo cluster dominante, che nasconde la varietà di regimi vissuta da ciascuna stazione.

Il *Time Series Forecasting* è una tecnica statistica che utilizza dati passati di una grandezza per stimarne i valori futuri, sfruttando la sequenza temporale delle osservazioni per anticipare tendenze, cicli e anomalie.

L'obiettivo è, quindi, sviluppare un modello predittivo in grado di stimare l'andamento futuro della temperatura ambientale basandosi su dati storici. La variabile analizzata è `Temp3pm`, la temperatura registrata alle ore 15:00, estratta dal dataset *weatherAUS*. L'analisi è limitata alla stazione di Sydney e i dati giornalieri sono aggregati su base mensile tramite la media. La serie risultante contiene 113 mesi, da febbraio 2008 a giugno 2017, con valori compresi fra 16,1 e 27,3 °C e media 21,6 °C.

Le due scelte di progetto meritano una motivazione esplicita, perché condizionano tutto il resto.

La **frequenza mensile** è preferita a quella giornaliera per due ragioni. La prima è statistica, in quanto la temperatura di un singolo giorno risente di molte fluttuazioni di breve periodo, mentre la media mensile le attenua e rende più netta la componente stagionale. La seconda è pratica, perché con dati mensili il ciclo annuale corrisponde ad un periodo stagionale $s = 12$, e i dieci anni disponibili forniscono quasi dieci ripetizioni complete del ciclo, sufficienti per stimarne i parametri. Con dati giornalieri la stima della componente stagionale diventerebbe molto più fragile, perché ogni giorno dell'anno comparirebbe solo dieci volte in tutta la serie.

La scelta di una **singola località** evita di mescolare stazioni con climi diversi, il che produrrebbe una serie priva di significato fisico, e di dover gestire le interruzioni delle stazioni meno coperte. Sydney ha una copertura quasi completa nel periodo considerato ed è quindi adatta allo scopo.

L'approccio metodologico adottato prevede l'utilizzo di diversi modelli autoregressivi a media mobile (ARIMA, SARIMA e SARIMAX) che richiedono una fase preliminare di preparazione della serie storica per garantire stazionarietà e continuità temporale. Segue, infine, il ciclo di Box-Jenkins che si occupa di tutte le fasi di analisi quali l'identificazione, la stima, la verifica diagnostica e la previsione.

5.1 Strumenti per l'analisi delle serie temporali

Questa sezione presenta la notazione e gli strumenti su cui si basa l'analisi, ovvero i concetti di stazionarietà e i test che la verificano, la decomposizione della serie, le funzioni di

autocorrelazione, la famiglia di modelli SARIMA con le sue alternative, e i criteri con cui i modelli vengono scelti e valutati.

5.1.1 Notazione

Una serie temporale è una successione di valori $y_1, y_2, \dots, y_n$ osservati a istanti equispaziati. L'indice t indica la posizione nella sequenza, ma non la data, e nella serie analizzata $t = 1$ corrisponde a febbraio 2008 e $t = 113$ a giugno 2017. Il valore y_{t-k} è quello osservato k passi prima, dove k è detto *ritardo* (*lag*). Con dati mensili y_{t-1} è il mese precedente e y_{t-12} lo stesso mese dell'anno precedente.

È comodo introdurre l'**operatore di ritardo** B , definito da

$$B y_t = y_{t-1}, \quad \text{e più in generale} \quad B^k y_t = y_{t-k}. \quad (5.1)$$

Con questa notazione la differenza ordinaria si scrive $(1 - B) y_t = y_t - y_{t-1}$ e quella stagionale di periodo s diventa $(1 - B^s) y_t = y_t - y_{t-s}$.

5.1.2 Stazionarietà e test ADF e KPSS

Un modello ARIMA stima una relazione fra il valore corrente e i valori passati assumendo che tale relazione non cambi nel tempo. Questa assunzione prende il nome di **stazionarietà in senso debole** e richiede tre condizioni: media costante, varianza costante e autocovarianza che dipenda solo dal ritardo k e non dall'istante t .

Una serie con un trend viola la prima condizione, perché la media cresce o cala; una serie con stagionalità marcata viola in pratica la stessa condizione, perché il livello atteso di gennaio è sistematicamente diverso da quello di luglio. In entrambi i casi la serie va trasformata prima di essere modellata, e lo strumento usato è la differenziazione.

Per stabilire quali differenziazioni siano necessarie si usano due test con ipotesi nulle opposte.

Il test **ADF** (*Augmented Dickey-Fuller*) stima la regressione

$$\Delta y_t = \alpha + \gamma y_{t-1} + \sum_{i=1}^k \delta_i \Delta y_{t-i} + \varepsilon_t \quad (5.2)$$

e verifica l'ipotesi nulla $H_0 : \gamma = 0$, cioè la presenza di una radice unitaria. Sotto H_0 la serie si comporta come una passeggiata aleatoria e non tende a tornare verso un livello medio, mentre con $\gamma < 0$ il valore corrente viene richiamato verso la media. La sommatoria è la parte *aumentata* del test e serve ad assorbire l'autocorrelazione residua. Un p -value basso rifiuta H_0 e fornisce evidenza di stazionarietà. Su serie brevi il test ha una potenza limitata, cioè fatica a rifiutare H_0 anche quando la serie è stazionaria.

Il test **KPSS** (*Kwiatkowski-Phillips-Schmidt-Shin*) adotta l'impostazione complementare, con ipotesi nulla di stazionarietà attorno a un livello costante. Tecnicamente scompone la serie in un trend deterministico, una passeggiata aleatoria e un errore, e verifica se la varianza della passeggiata aleatoria sia nulla. Il p -value del KPSS si ricava per interpolazione da una tavola di valori critici ed è quindi disponibile solo nell'intervallo $[0,01; 0,10]$, per cui un valore pari a 0,10 va letto come " $\geq 0,10$ ".

Con due test di ipotesi opposte le conclusioni solide sono quelle in cui entrambi puntano nella stessa direzione.

5.1.3 Decomposizione classica

La **decomposizione classica** scompone la serie in tre elementi. Nella forma additiva

$$y_t = T_t + S_t + R_t, \quad (5.3)$$

dove T_t è il trend, S_t la componente stagionale e R_t il residuo. Il trend viene stimato con una media mobile centrata sul periodo stagionale, la componente stagionale come profilo medio dei dodici mesi calcolato al netto del trend, e il residuo per differenza.

L'alternativa moltiplicativa, $y_t = T_t \cdot S_t \cdot R_t$, è appropriata quando l'ampiezza delle oscillazioni cresce al crescere del livello della serie. Per scegliere fra le due forme si controlla se la dispersione dei residui additivi aumenta nel tempo e quale delle due decomposizioni lasci un residuo più piccolo. Va considerato anche che la temperatura in gradi Celsius è misurata su una scala a intervalli, il cui zero è convenzionale, per cui un modello in cui le componenti si moltiplicano darebbe risultati dipendenti dall'unità di misura scelta.

5.1.4 Autocorrelazione: ACF e PACF

La **funzione di autocorrelazione** (ACF) misura la correlazione fra la serie e una sua copia ritardata di k passi,

$$\rho(k) = \text{Corr}(y_t, y_{t-k}) = \frac{\text{Cov}(y_t, y_{t-k})}{\text{Var}(y_t)}. \quad (5.4)$$

Un valore elevato al ritardo 12 su una serie mensile indica che il valore di un mese è legato a quello dello stesso mese dell'anno precedente, cioè segnala stagionalità annuale. Nei grafici le bande azzurre rappresentano l'intervallo entro cui un'autocorrelazione è compatibile con lo zero e i valori interni alle bande non sono distinguibili dal rumore. Per n osservazioni la loro ampiezza è circa $\pm 1,96/\sqrt{n}$.

L'ACF, però, non distingue i legami diretti da quelli propagati. Se y_t dipende da y_{t-1} e y_{t-1} dipende da y_{t-2} , allora y_t risulta correlato con y_{t-2} anche in assenza di un legame proprio fra i due.

La **funzione di autocorrelazione parziale** (PACF) risolve il problema misurando la correlazione fra y_t e y_{t-k} al netto dei ritardi intermedi $1, \dots, k-1$, cioè il contributo che il ritardo k aggiunge quando i precedenti sono già nel modello. È l'analogo temporale della differenza fra correlazione semplice e coefficiente di una regressione multipla.

Le due funzioni si usano insieme perché i due processi elementari lasciano firme complementari, riassunte in Tabella 5.1.

Tabella 5.1: Comportamento di ACF e PACF per i processi elementari.

Processo	ACF	PACF
AR(p): $y_t = \phi_1 y_{t-1} + \dots + \phi_p y_{t-p} + \varepsilon_t$	decade gradualmente	si tronca dopo il ritardo p
MA(q): $y_t = \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}$	si tronca dopo il ritardo q	decade gradualmente

La differenza sostanziale fra i due processi è che in un AR il valore corrente dipende dai *valori* passati, per cui l'effetto di uno shock si propaga indefinitamente e l'ACF decade lentamente, mentre in un MA dipende dagli *errori* passati, per cui uno shock resta in memoria solo per q periodi e l'ACF si azzerà bruscamente.

5.1.5 ARIMA, SARIMA e SARIMAX

Il modello ARIMA(p, d, q) combina una componente autoregressiva di ordine p , d differenziazioni ordinarie e una componente a media mobile di ordine q . Quando la serie ha una

stagionalità di periodo s , il modello viene esteso a $\text{SARIMA}(p, d, q)(P, D, Q)_s$, che aggiunge un secondo blocco identico operante a distanza s .

I parametri hanno quindi due letture parallele. Gli ordini p e q descrivono la dipendenza fra mesi consecutivi, gli ordini P e Q quella fra mesi distanti un anno. Il parametro d conta le differenziazioni ordinarie e D quelle stagionali. In entrambi i casi il numero indica quante volte l'operazione viene applicata, non il ritardo a cui opera, che è specificato da s . Con $D = 1$ e $s = 12$ ogni mese viene confrontato con lo stesso mese dell'anno precedente; poiché i mesi di gennaio hanno valori simili fra loro, l'operazione rimuove il ciclo annuale e lascia la variazione interannuale.

Il modello SARIMAX aggiunge infine dei regressori esterni x_t , detti **variabili esogene**. La parte di regressione spiega il livello attraverso variabili esterne e la parte SARIMA descrive la struttura residua dell'errore. Per prevedere con un SARIMAX occorre conoscere i valori futuri dei regressori.

Termine deterministico. Un SARIMA può includere una costante c . Dopo la differenziazione stagionale la costante rappresenta la variazione media da un anno al successivo, cioè una **deriva**, in cui con $c \neq 0$ il modello prevede un livello che cresce o cala linearmente nel tempo. In presenza di una componente $\text{AR}(1)$, la variazione annua media implicata dal modello è $c/(1 - \phi_1)$. Un modello senza costante impone invece una variazione media annua nulla, per cui l'inclusione della costante va decisa esplicitamente.

Stagionalità stocastica e deterministica. La differenziazione stagionale tratta il ciclo come *stocastico*, libero in linea di principio di cambiare da un anno all'altro. L'alternativa è trattarlo come *deterministico*, cioè come un profilo fisso che si ripete identico, rappresentato da regressori noti anche per il futuro. Per fare ciò sono stati utilizzati:

- **dodici dummy mensili**, una per ciascun mese; le dummy complete forniscono già il livello, per cui non si aggiunge una costante, che creerebbe collinearità esatta;
- **termini di Fourier** di ordine K , cioè le coppie

$$\sin\left(\frac{2\pi kt}{12}\right), \quad \cos\left(\frac{2\pi kt}{12}\right), \quad k = 1, \dots, K, \quad (5.5)$$

che descrivono il ciclo con funzioni periodiche lisce usando $2K$ parametri invece di dodici. Poiché hanno media nulla, richiedono una costante.

Le due rappresentazioni sono legate. Se nel modello SARIMA il coefficiente MA stagionale Θ_1 vale -1 , il fattore $(1 + \Theta_1 B^{12}) = (1 - B^{12})$ a destra coincide con la differenza stagionale a sinistra, e i due si compensano; in questo modo, il modello equivale a un profilo stagionale fisso, più un trend lineare generato dalla deriva, più la componente AR. Un Θ_1 stimato vicino a -1 è quindi il segnale classico di una stagionalità di fatto deterministica.

5.1.6 Criteri di selezione, metriche di errore e diagnostica

Il confronto fra modelli stimati sugli stessi dati usa i criteri informativi AIC e BIC, che sommano alla bontà di adattamento una penalità per il numero di parametri k :

$$\text{AIC} = -2 \ln \hat{L} + 2k, \quad \text{BIC} = -2 \ln \hat{L} + k \ln n, \quad (5.6)$$

dove $\hat{L}$ è la verosimiglianza massimizzata e n il numero di osservazioni. Valori più bassi indicano un compromesso migliore fra adattamento e parsimonia, e il BIC penalizza la

complessità in maniera più severa. Due limiti vanno tenuti presenti: i criteri misurano l'adattamento e non la capacità predittiva, e sono confrontabili solo fra modelli con la stessa differenziazione, perché la verosimiglianza di un modello con $D = 1$ è calcolata sulla serie differenziata e non su quella originale.

La valutazione delle previsioni usa l'errore assoluto medio e la radice dell'errore quadratico medio,

$$\text{MAE} = \frac{1}{n} \sum_{t=1}^n |y_t - \hat{y}_t|, \quad \text{RMSE} = \sqrt{\frac{1}{n} \sum_{t=1}^n (y_t - \hat{y}_t)^2}, \quad (5.7)$$

entrambe espresse in gradi Celsius; il RMSE, elevando al quadrato, penalizza maggiormente gli errori grandi. Si riporta anche il **bias**, cioè la media di $\hat{y}_t - y_t$, che indica se il modello sovrastima o sottostima sistematicamente. L'errore percentuale medio (MAPE) è calcolato solo a titolo indicativo, perché su una scala a intervalli come quella Celsius un errore rapportato al valore osservato ha un significato fisico debole.

Un modello adeguato deve infine lasciare residui simili a rumore bianco, cioè privi di struttura sfruttabile. Il test di **Ljung-Box** verifica congiuntamente la nullità delle prime h autocorrelazioni dei residui attraverso la statistica

$$Q(h) = n(n+2) \sum_{k=1}^h \frac{\hat{\rho}_k^2}{n-k}, \quad (5.8)$$

con ipotesi nulla di indipendenza. Quando il test si applica ai residui di un modello stimato, i gradi di libertà vanno ridotti del numero di parametri stimati.

5.2 Preparazione della serie

La costruzione della serie mensile a partire dal dataset giornaliero si articola nei passaggi seguenti.

- **Selezione dei dati.** La colonna `Date` viene convertita in formato *datetime* e impostata come indice. Vengono quindi selezionate le osservazioni di Sydney e la variabile `Temp3pm`.
- **Aggregazione mensile.** I dati giornalieri vengono ricampionati su base mensile calcolando la media delle rilevazioni di ciascun mese. Si ottengono 113 osservazioni mensili.
- **Controlli di qualità.** Si individuano i mesi privi di osservazioni, che risultano tre (aprile 2011, dicembre 2012 e febbraio 2013), e si conta il numero di giorni che compone ciascuna media mensile. La mediana è di 31 giorni e il minimo, fra i mesi non vuoti, di 25. Tutte le medie sono quindi affidabili.
- **Suddivisione in training e test.** Gli ultimi 24 mesi, pari a due cicli stagionali completi, costituiscono il test (luglio 2015 – giugno 2017), mentre i primi 89 rappresentano il training (febbraio 2008 – giugno 2015). La suddivisione avviene *prima* di qualsiasi analisi (Figura 5.1).
- **Imputazione.** I tre mesi mancanti vengono ricostruiti con un'interpolazione temporale applicata *al solo training*. Si è verificato che nessun mese mancante cada nel periodo di test.

L'ordine delle ultime due operazioni riguarda una forma di *lookahead* che non dipende dal modello ma dalla preparazione dei dati. L'interpolazione temporale utilizza anche il punto *successivo* a quello mancante, infatti nel caso in cui un mese assente cadesse a ridosso del confine fra i due insiemi, verrebbe ricostruito con un valore del test, cioè con informazione non disponibile al momento della previsione. Nel caso concreto i tre mesi mancanti sono lontani dal confine e interni al training, per cui interpolare prima o dopo la suddivisione dà gli stessi valori. La procedura adottata resta comunque quella corretta, perché non dipende da dove cadono i mesi mancanti e continuerebbe a evitare il lookahead anche con dati diversi.




Figura 5.1: Temperatura pomeridiana media mensile a Sydney e suddivisione in training (febbraio 2008 – giugno 2015) e test (luglio 2015 – giugno 2017).

5.3 Protocollo sperimentale

Una valutazione affidabile richiede che il test non influenzi, nemmeno indirettamente, alcuna scelta di modello. Se l'analisi esplorativa o la lettura dei correlogrammi includessero i mesi di test, gli ordini del modello sarebbero scelti anche in base al periodo su cui poi viene valutato, e l'errore stimato risulterebbe ottimistico. Il protocollo adotta quindi un principio unico, ovvero **tutte le scelte si basano sul solo training**, e il test viene usato una sola volta, alla fine.

Le fasi dell'analisi sono le seguenti.

1. *Analisi esplorativa del training*: fase in cui viene analizzato l'andamento della serie, il ciclo annuale, la decomposizione e la scelta fra forma additiva e moltiplicativa.
2. *Stazionarietà*: vengono effettuati i test ADF e KPSS sul training, prima e dopo la differenziazione stagionale, per fissare d e D .
3. *Identificazione*: lettura di ACF e PACF del training differenziato fino al ritardo 26, per proporre gli ordini p, q, P, Q .
4. *Termine deterministico*: confronto per AIC fra il modello proposto con e senza costante, affiancato dalla media della serie differenziata.
5. *Stima e selezione degli ordini*: confronto per AIC e BIC di una rosa di candidati suggeriti dai correlogrammi e, come controprova, ricerca esaustiva con $p, q \in \{0, 1, 2\}$ e $P, Q \in \{0, 1\}$, con d, D, s e termine deterministico fissati, per 36 combinazioni. I vincoli di stazionarietà e invertibilità restano attivi.
6. *Diagnostica dei residui* del modello stimato sul training, con il test di Ljung-Box ai ritardi 6, 12, 18 e 24. Si escludono i primi 12 residui, che riflettono l'inizializzazione della

differenza stagionale e non errori di previsione, e si correggono i gradi di libertà per i tre parametri stimati diversi dalla varianza.

7. *Validazione a origine mobile*: confronto fra famiglie di modelli, descritto di seguito.
8. *Valutazione finale* del modello scelto sul test, con previsioni a 24 passi che non usano alcun valore del test.
9. *Previsione*: il modello scelto viene riaddestrato sull'intera serie e prevede i 12 mesi successivi.

5.3.1 Validazione a origine mobile

L'AIC consente di scegliere gli ordini all'interno della famiglia SARIMA, ma non di confrontarla con i modelli a stagionalità deterministica, che non differenziano la serie. Per confrontare famiglie diverse serve una misura di errore di previsione, e per non trasformare il test in un insieme di selezione questa misura va calcolata all'interno del training.

Si usa quindi una **validazione a origine mobile**. Il modello viene addestrato sui primi n_i mesi del training e prevede i 12 mesi successivi; l'operazione è ripetuta per 5 origini distanziate di 6 mesi, con finestre di addestramento di 53, 59, 65, 71 e 77 mesi. L'ultimo fold termina esattamente alla fine del training (giugno 2015). Per ogni modello si calcola il MAE di ciascun fold e la sua media.

I modelli confrontati sono riportati nella Tabella 5.2. I *candidati* sono le famiglie fra cui si sceglie il modello finale. Le *varianti diagnostiche* tolgono il termine deterministico a un candidato, in quanto non partecipano alla scelta, ma servono a separare l'effetto della rappresentazione della stagionalità da quello del trend.

Tabella 5.2: Modelli confrontati nella validazione a origine mobile.

Modello	Ruolo	Stagionalità	Termine deterministico
SARIMA selezionato	candidato	differenziata ($D = 1$)	deriva
AR(1) + dummy mensili + trend	candidato	12 dummy	trend lineare
AR(1) + Fourier $K = 2$ + trend	candidato	4 termini di Fourier	costante e trend lineare
SARIMA + esogene previste	candidato	differenziata	deriva
SARIMA senza costante	diagnostica	differenziata	nessuno
AR(1) + Fourier $K = 2$ senza trend	diagnostica	4 termini di Fourier	sola costante
Baseline naïve stagionale	riferimento	ripete gli ultimi 12 mesi	–

Regola di scelta. La regola è fissata prima di osservare i risultati. Si individua il candidato con il MAE medio più basso, successivamente, per ogni altro candidato si calcola la differenza di MAE rispetto al migliore fold per fold, con il relativo errore standard. Il confronto è *abbinato*, perché tutti i modelli sono valutati sugli stessi fold, e questo elimina la variabilità dovuta alla diversa difficoltà dei periodi. Fra i candidati la cui differenza media non supera un errore standard (*regola dell'errore standard*) si sceglie quello con meno parametri. Differenze di questa entità, infatti, non sono distinguibili dal rumore della validazione, e a parità di errore il modello più parsimonioso è preferibile.

5.3.2 Baseline e variabili esogene

Il modello scelto viene confrontato con una **baseline naïve stagionale**, che prevede per ogni mese il valore osservato nello stesso mese dell'anno precedente, $\hat{y}_t = y_{t-12}$. Con un orizzonte di 24 mesi, uno spostamento di dodici mesi applicato alla serie completa userebbe

per il secondo anno i valori reali del primo anno di test. La baseline viene quindi costruita ripetendo due volte gli ultimi dodici mesi del training, così che anch'essa sia una previsione realizzabile.

Il modello con esogene usa `Humidity3pm` e `Pressure3pm`, aggregate mensilmente con la stessa procedura della temperatura:

$$\text{Temp3pm}_t = \beta_1 \cdot \text{Humidity3pm}_t + \beta_2 \cdot \text{Pressure3pm}_t + \eta_t, \quad (5.9)$$

con η_t descritto dalla stessa struttura SARIMA del modello univariato. Poiché il modello richiede le covariate nello stesso mese da prevedere, e in una previsione reale quei valori sono ignoti quanto la temperatura, si distinguono due scenari:

- **esogene previste:** le covariate dei mesi futuri sono a loro volta previste con la regola naïve stagionale, usando solo i dati passati. È la previsione realizzabile, ed è quella usata nella validazione;
- **oracolo:** si usano i valori reali delle covariate nel test. Non è una previsione realizzabile, ma un limite superiore che quantifica quanto varrebbero le esogene se fossero note in anticipo. È calcolato solo a scopo descrittivo.

Anche per le esogene l'imputazione dei mancanti avviene separatamente per ogni periodo, così che nessun valore futuro contribuisca a ricostruire quelli passati.

5.4 Risultati

I risultati sono presentati nell'ordine delle fasi del protocollo.

5.4.1 Analisi esplorativa

Il grafico della serie in Figura 5.1, limitato al periodo di training, mostra subito la caratteristica dominante, cioè un ciclo annuale molto regolare, con valori elevati nei mesi estivi e bassi in quelli invernali. Sovrapponendo gli anni e osservando la distribuzione dei valori per mese (Figura 5.2) la regolarità diventa ancora più evidente. Poiché Sydney si trova nell'emisfero australe, il ciclo è invertito rispetto a quello europeo, ovvero il massimo cade fra dicembre e febbraio e il minimo fra giugno e agosto.




Figura 5.2: Training: a sinistra gli anni sovrapposti, a destra la distribuzione della temperatura per mese.

La decomposizione additiva del training (Figura 5.3) fornisce le indicazioni seguenti.

- **Trend:** la curva oscilla in un intervallo ristretto, fra 20,7 e 22,4 °C, quindi meno di due gradi contro i dieci di escursione della serie. Non si riconosce una direzione netta, ma un'alternanza di periodi più freddi e più caldi.

- **Stagionalità:** il profilo si ripete ogni dodici mesi con un'ampiezza di $8,8^{\circ}\text{C}$ fra picco e valle.
- **Residui:** essi appaiono centrati sullo zero e privi di pattern riconoscibili, con deviazione standard di $0,82^{\circ}\text{C}$.




Figura 5.3: Decomposizione additiva del training in componente osservata, trend, stagionalità e residuo.

Il confronto fra le componenti è già di per sé informativo, perché la stagionalità è di un ordine di grandezza superiore al rumore residuo ($8,8$ contro $0,82^{\circ}\text{C}$). Una previsione che riproduca correttamente il ciclo annuale risulta quindi accurata quasi per costruzione, e lo spazio di miglioramento rispetto a una regola che ripete il ciclo è ristretto.

La forma additiva è confermata da entrambi i controlli. La deviazione standard dei residui passa da $0,781$ nella prima metà del training a $0,865$ nella seconda, con un rapporto di $1,11$. È possibile osservare che le fluttuazioni non si amplificano nel tempo. Inoltre il residuo additivo ($0,819$) è inferiore a quello moltiplicativo riportato alla stessa scala ($0,847$).

5.4.2 Stazionarietà

La Tabella 5.3 riporta i test sul training prima e dopo la differenziazione stagionale.

Tabella 5.3: Test di stazionarietà sul training, prima e dopo la differenziazione stagionale.

Serie	Test	Statistica	p -value	Esito
Originale	ADF	-1,567	0,500	non rifiuta la radice unitaria
Originale	KPSS	0,059	$\geq 0,10$	non rifiuta la stazionarietà
Differenziata	ADF	-2,797	0,059	al limite della significatività
Differenziata	KPSS	0,140	$\geq 0,10$	non rifiuta la stazionarietà

Sulla serie originale i due test non concordano, perché l'ADF non rifiuta la radice unitaria e il KPSS non rifiuta la stazionarietà. Non si tratta di un errore, ma del sintomo tipico di una serie a forte stagionalità, che nessuno dei due test gestisce in modo esplicito.

Dopo la differenziazione stagionale (Figura 5.4) il ciclo non è più visibile e il KPSS continua a non rifiutare la stazionarietà, mentre l'ADF si colloca al limite della significatività ($p = 0,059$). La conclusione non è quindi netta, in quanto con 77 osservazioni differenziate il test ADF ha potenza limitata. La scelta $D = 1$ con $s = 12$ si appoggia anche sull'andamento della serie differenziata e sul rapido decadimento dell'ACF, ed è comunque messa alla prova nella validazione, dove il SARIMA viene confrontato con modelli che non differenziano la serie. Non si applica invece differenziazione ordinaria ($d = 0$), perché il KPSS sulla serie originale non rileva un trend stocastico.




Figura 5.4: Training differenziato stagionalmente al ritardo 12.

5.4.3 Identificazione degli ordini

I correlogrammi del training differenziato sono riportati in Figura 5.5; la banda di significatività è di circa $\pm 0,22$.




Figura 5.5: ACF e PACF del training differenziato stagionalmente.

Per la **parte non stagionale**, ACF e PACF presentano un picco positivo significativo al ritardo 1 pari a 0,32, dopo il quale la PACF rientra subito nelle bande (0,05 al ritardo 2). Il

troncamento della PACF dopo il primo ritardo è la firma di una componente autoregressiva di ordine uno, quindi $p = 1$. L'ACF non mostra un troncamento altrettanto netto, per cui si pone inizialmente $q = 0$, verificando l'alternativa $q = 1$ con l'AIC.

Per la **parte stagionale**, al ritardo 12 entrambe le funzioni mostrano un picco negativo marcato ($-0,42$ per l'ACF e $-0,36$ per la PACF), mentre al ritardo 24 l'ACF non è più significativa ($0,02$). L'autocorrelazione si tronca dopo il primo ritardo stagionale, che è la firma di una componente a media mobile stagionale: $Q = 1$ e $P = 0$. La specificazione proposta è pertanto

$$\text{SARIMA}(1, 0, 0)(0, 1, 1)_{12}. \quad (5.10)$$

5.4.4 Termine deterministico

Il confronto sul training favorisce il modello con costante, con AIC pari a 236,5 contro 238,6 del modello senza costante, mentre il BIC, più severo, risulta praticamente equivalente con valore pari a 245,9 contro 245,6. La media della serie differenziata è $+0,122^\circ\text{C}$, positiva ma con un errore standard di 0,160. Seguendo il criterio dichiarato nel protocollo si include quindi nel modello una costante che, dopo la differenziazione stagionale, rappresenta la variazione media da un anno all'altro (la deriva). La costante è mantenuta in tutte le stime successive, così che la selezione degli ordini si riferisca al modello effettivamente valutato.

5.4.5 Stima e selezione degli ordini

Il modello proposto dai correlogrammi risulta il migliore sia per AIC sia per BIC fra i candidati (Tabella 5.4). Il secondo, che sostituisce $p = 1$ con $q = 1$, dista appena 1,1 punti di AIC e possiamo dedurre che su questa serie le due formulazioni sono quasi equivalenti, come suggeriva la lettura dei correlogrammi. I modelli con componente autoregressiva stagionale ($P = 1$, $Q = 0$) sono invece nettamente peggiori, coerentemente con il troncamento dell'ACF dopo il ritardo 12.

Tabella 5.4: Confronto dei modelli candidati con deriva, stimati sul training.

Modello	AIC	BIC
$(1, 0, 0)(0, 1, 1)_{12}$	236,5	245,9
$(0, 0, 1)(0, 1, 1)_{12}$	237,6	247,0
$(1, 0, 1)(0, 1, 1)_{12}$	237,9	249,6
$(2, 0, 0)(1, 1, 1)_{12}$	239,7	253,7
$(1, 0, 1)(1, 1, 0)_{12}$	246,4	258,1
$(1, 0, 0)(1, 1, 0)_{12}$	246,8	256,2

La ricerca esaustiva sulle 36 combinazioni seleziona lo stesso modello, $(1, 0, 0)(0, 1, 1)_{12}$, con AIC pari a 236,497; una sola combinazione non raggiunge la convergenza piena dell'ottimizzatore, senza effetti sulla scelta. La convergenza di due procedure indipendenti, una grafica e una numerica, rafforza la scelta degli ordini. Si è preferita una ricerca esaustiva a una procedura *stepwise* perché quest'ultima può arrestarsi in un minimo locale, mentre la griglia garantisce il minimo sull'insieme considerato.

I coefficienti stimati sono riportati nella Tabella 5.5.

Tabella 5.5: Coefficienti del SARIMA(1,0,0)(0,1,1)₁₂ con deriva, stimati sul training.

Parametro	Stima	Errore std.	z	p -value
Costante (deriva) c	0,095	0,058	1,63	0,104
AR(1) ϕ_1	0,292	0,108	2,69	0,007
MA stagionale Θ_1	-0,998	38,38	-0,03	0,979
Varianza σ^2	0,834	31,94	0,03	0,979

Il modello stimato si scrive per esteso come

$$(1 - \phi_1 B)(1 - B^{12})y_t = c + (1 + \Theta_1 B^{12})\varepsilon_t. \quad (5.11)$$

- Il **coefficiente autoregressivo** vale 0,292, è significativo ($p = 0,007$) e soddisfa la condizione di stazionarietà $|\phi_1| < 1$, ovvero poco meno di un terzo dello scostamento del mese precedente si trasmette al mese corrente.
- La **deriva** vale 0,095 con $p = 0,104$, quindi non è significativa al 5%. Tenendo conto della componente AR, corrisponde ad una variazione media di $0,095/(1 - 0,292) \approx 0,13^\circ\text{C}$ all'anno, coerente con la media della serie differenziata.
- Il **coefficiente MA stagionale** vale -0,998, praticamente -1, con un errore standard enorme. È il comportamento tipico di un parametro sul bordo della regione di invertibilità, dove la verosimiglianza è quasi piatta, per cui errori standard e p -value non sono interpretabili, mentre le previsioni puntuali restano valide. I vincoli di invertibilità vanno per questo lasciati attivi. Come visto nella Sezione 5.1.5, un valore di -1 indica che la differenza stagionale e il termine MA si compensano, quindi il modello descrive di fatto un ciclo stagionale fisso più un trend lineare. L'ipotesi viene verificata nella validazione.

5.4.6 Diagnostica dei residui

La diagnostica grafica (Figura 5.6) e il test di Ljung-Box (Tabella 5.6) non rilevano struttura residua, in quanto tutti i p -value superano 0,05, quindi l'ipotesi di indipendenza non viene rifiutata a nessuno dei ritardi considerati. I residui hanno media +0,032, prossima a zero, e deviazione standard pari a 1,108.




Figura 5.6: Diagnostica dei residui del modello stimato sul training: residui standardizzati, istogramma con densità stimata, Q-Q plot e correlogramma.

Tabella 5.6: Test di Ljung-Box sui residui, esclusi i primi 12 e con 3 gradi di libertà sottratti.

Ritardo	Statistica Q	p-value
6	5,938	0,115
12	9,671	0,378
18	10,225	0,805
24	17,867	0,657

Come controprova, il test applicato senza escludere i residui iniziali restituisce $p < 0,0001$ al ritardo 12, un risultato apparentemente disastroso. Il confronto mostra quanto la diagnostica dipenda da un dettaglio di calcolo, perché quel valore è determinato dai residui di inizializzazione e non da un difetto del modello.

5.4.7 Validazione a origine mobile

La Tabella 5.7 riporta il MAE dei modelli in ciascun fold e la sua media.

Tabella 5.7: MAE (°C) della validazione a origine mobile sul training: previsioni a 12 mesi da 5 origini.

Modello	Fold 1	Fold 2	Fold 3	Fold 4	Fold 5	Media	N. param.
SARIMA selezionato	0,550	1,153	1,362	0,812	0,687	0,913	4
SARIMA + esogene previste	0,504	1,063	1,269	0,932	0,796	0,913	6
AR(1) + dummy mensili + trend	0,554	1,158	1,365	0,810	0,680	0,914	15
AR(1) + Fourier $K = 2$ + trend	0,730	1,160	1,331	0,748	0,633	0,920	8
<i>SARIMA senza costante</i>	0,534	1,192	1,447	0,991	0,664	0,965	3
<i>AR(1) + Fourier $K = 2$ senza trend</i>	0,480	1,187	1,419	0,884	0,572	0,908	7
Baseline naïve stagionale	0,951	1,176	1,185	1,222	1,333	1,173	–

Scelta del modello. Fra i candidati il MAE medio più basso è quello del SARIMA selezionato (0,913). Gli altri tre gli restano entro un errore standard nel confronto abbinato: SARIMA con esogene previste ($+0,000 \pm 0,048$), AR(1) con dummy e trend ($+0,001 \pm 0,002$) e AR(1) con Fourier e trend ($+0,007 \pm 0,045$). Applicando la regola del protocollo si sceglie il modello con meno parametri, cioè il **SARIMA(1, 0, 0)(0, 1, 1)₁₂ con deriva**, con 4 parametri.

Stagionalità differenziata o deterministica. Il SARIMA e il modello con dummy mensili e trend commettono errori quasi identici in ogni fold, con differenze di pochi millesimi di grado. È la conferma empirica dell’equivalenza attesa con $\Theta_1 \approx -1$, in cui la differenza stagionale compensata dal termine MA descrive un ciclo fisso, esattamente come le dummy. La stagionalità della temperatura a Sydney è quindi di fatto deterministica, come ci si aspetta da un fenomeno governato dal ciclo solare. La differenziazione non è dannosa, ma nemmeno aggiunge flessibilità, in quanto le due parametrizzazioni sono due modi di scrivere lo stesso modello, e il SARIMA lo fa con meno parametri.

Effetto del termine deterministico. Togliere la costante al SARIMA peggiora il MAE medio di $0,053 \pm 0,037$, cioè di circa 1,4 errori standard, con un peggioramento concentrato negli ultimi fold. Per i modelli di Fourier, invece, il trend non porta vantaggi in validazione ($-0,012 \pm 0,068$), e nel primo fold, con la finestra di addestramento più corta, lo peggiora sensibilmente. Il trend lineare stimato su pochi cicli è infatti instabile, e la sua utilità dipende dal periodo su cui si prevede.

Variabili esogene. Con le covariate previste dal solo passato, il modello con esogene ha lo stesso MAE medio del SARIMA univariato (0,913). Umidità e pressione non aggiungono informazione utile a una previsione realizzabile.

Tutti i modelli, infine, sono nettamente migliori della baseline naïve stagionale (1,173).

5.4.8 Valutazione sul test

Il SARIMA scelto viene addestrato sull’intero training e valutato sui 24 mesi di test. La Tabella 5.8 riporta anche gli altri modelli, a scopo descrittivo. I loro risultati sul test non modificano la scelta, altrimenti il test diventerebbe un insieme di selezione.

Tabella 5.8: Prestazioni sui 24 mesi di test.

Modello	MAE	RMSE	MAPE (%)	Bias
AR(1) + Fourier $K = 2$ + trend	0,769	0,901	3,54	+0,121
SARIMA(1, 0, 0)(0, 1, 1)₁₂ con deriva	0,801	0,967	3,63	−0,024
AR(1) + dummy mensili + trend	0,812	0,986	3,69	−0,030
SARIMA + esogene previste	0,848	1,045	3,84	−0,302
Baseline naïve stagionale	0,893	1,074	4,06	−0,478
AR(1) + Fourier $K = 2$ senza trend	0,908	1,131	3,97	−0,653
SARIMA senza costante	0,995	1,176	4,37	−0,646

In tabella, il modello scelto in validazione è in grassetto, mentre gli altri sono riportati a scopo descrittivo. Il bias, invece, indica la media di previsto meno reale.

In particolare, il modello scelto riduce il MAE da 0,893 a 0,801 °C, cioè del 10,3% rispetto alla baseline, e il RMSE da 1,074 a 0,967 °C, con una riduzione del 9,9% (Figura 5.7).

Il margine va letto tenendo conto della forza della stagionalità. In dettaglio, la baseline cattura gratuitamente quasi tutto il segnale, e con un ciclo di 8,8 °C contro un residuo di 0,82 °C ridurre l'errore di un decimo di grado è un risultato sostanziale.




Figura 5.7: Previsione a 24 mesi del modello scelto sul test, con intervallo di confidenza al 95% e baseline naïve stagionale.

Il confronto descrittivo con gli altri modelli conferma quanto emerso in validazione, con una differenza. Il modello con dummy e trend ottiene un MAE quasi identico a quello del SARIMA (0,812), a riprova della loro equivalenza. Il modello di Fourier con trend risulta invece il migliore sul test (0,769), pur non essendo stato scelto: in validazione la sua differenza dal SARIMA non era distinguibile dal rumore, e rivedere la scelta alla luce del test ne comprometterebbe il ruolo di stima imparziale. Il risultato indica comunque che una rappresentazione deterministica e parsimoniosa del ciclo è un'alternativa competitiva.

Sul test il ruolo del termine deterministico è evidente. I due modelli senza trend hanno un bias di circa −0,65 °C e sono peggiori della baseline, mentre le rispettive versioni con trend hanno bias quasi nullo. Il periodo di test è stato mediamente più caldo di quanto un ciclo senza deriva possa prevedere, e solo i modelli che proiettano la tendenza di fondo lo colgono.

Analisi dell'errore. L'errore mese per mese del modello scelto è riportato in Figura 5.8.

- Il **bias** è praticamente nullo ($-0,024^{\circ}\text{C}$): sovrastime e sottostime si alternano senza una direzione sistematica.
- L'**errore massimo** è di $1,83^{\circ}\text{C}$, una sovrastima a settembre 2015. Le sottostime più ampie, fra $1,3$ e $1,6^{\circ}\text{C}$, riguardano mesi risultati più caldi del previsto, come dicembre 2016, febbraio 2016, ottobre 2015 e maggio 2016.
- Le previsioni sono **meno variabili** dei dati osservati, con una deviazione standard di $2,99^{\circ}\text{C}$ contro $3,46^{\circ}\text{C}$, pari a un rapporto di $0,86$. È il comportamento atteso di una previsione a più passi, che tende al profilo medio e non può riprodurre gli scostamenti eccezionali dei singoli mesi.




Figura 5.8: Errore di previsione mese per mese sul test (previsto meno reale), con le sovrastime in rosso e le sottostime in blu.

5.4.9 Variabili esogene e rischio di lookahead

Nel modello con esogene stimato sul training (Tabella 5.9) solo l'umidità risulta significativa, con coefficiente $-0,104$ e $p < 0,001$. A parità delle altre componenti, un punto percentuale di umidità media mensile in più si associa a una temperatura pomeridiana inferiore di circa un decimo di grado, il che è fisicamente sensato perché i mesi più umidi tendono a essere anche più nuvolosi. La pressione non è significativa ($p = 0,655$).

Tabella 5.9: Coefficienti del SARIMAX con variabili esogene, stimati sul training.

Parametro	Stima	Errore std.	z	p-value
Costante	0,063	0,059	1,07	0,287
Humidity3pm	-0,104	0,029	-3,62	< 0,001
Pressure3pm	0,021	0,048	0,45	0,655
AR(1) ϕ_1	0,238	0,131	1,81	0,070
MA stagionale Θ_1	-0,998	37,99	-0,03	0,979

La significatività dei coefficienti non basta però a stabilire se le esogene migliorino la previsione. La Tabella 5.10 e la Figura 5.9 confrontano i due scenari sul test.

Tabella 5.10: Modello con esogene nei due scenari, confrontato con il modello univariato e la baseline sul test. Lo scenario oracolo usa i valori futuri reali delle covariate e non costituisce una previsione realizzabile.

Modello	MAE	RMSE	MAPE (%)	Bias
SARIMAX + esogene (<i>oracolo</i> , non realizzabile)	0,665	0,775	3,02	−0,004
SARIMA con deriva (univariato)	0,801	0,967	3,63	−0,024
SARIMAX + esogene previste	0,848	1,045	3,84	−0,302
Baseline naïve stagionale	0,893	1,074	4,06	−0,478




Figura 5.9: Valori reali sul test e previsioni del modello univariato e del modello con esogene nei due scenari.

Nello scenario *oracolo* il MAE scende da 0,801 a 0,665 °C, con un miglioramento del 17% che renderebbe il modello con esogene il migliore su tutte le metriche. Appena le covariate devono essere previste, però, il MAE sale a 0,848 °C; in questo caso, il modello resta migliore della baseline, ma diventa peggiore del SARIMA univariato, in accordo con quanto osservato in validazione. La distanza fra 0,665 e 0,848 misura il costo di non conoscere il futuro, in quanto prevedere le covariate introduce più incertezza di quanta informazione esse aggiungano.

Il miglioramento dello scenario *oracolo* non è quindi un guadagno reale ma un artefatto del lookahead, ed è per questo che i due scenari vanno tenuti separati e dichiarati come tali. Il confronto conserva comunque valore, perché distingue il limite del modello dal limite dell'informazione disponibile al momento della previsione.

5.4.10 Previsione dei mesi successivi

Terminata la valutazione, il modello scelto viene riaddestrato sull'intera serie con la stessa specificazione, ovvero SARIMA(1,0,0)(0,1,1)₁₂ con deriva e senza esogene, e prevede i dodici mesi successivi alla fine dei dati (Tabella 5.11 e Figura 5.10).

Tabella 5.11: Previsione dei dodici mesi successivi alla fine della serie, in gradi Celsius, con intervallo di confidenza al 95%.

Mese	Prev.	IC inf.	IC sup.	Mese	Prev.	IC inf.	IC sup.
2017-07	17,5	15,7	19,4	2018-01	26,5	24,6	28,5
2017-08	18,7	16,7	20,6	2018-02	26,2	24,3	28,1
2017-09	20,8	18,8	22,7	2018-03	25,3	23,4	27,2
2017-10	22,3	20,4	24,3	2018-04	22,7	20,8	24,7
2017-11	23,8	21,8	25,7	2018-05	20,8	18,8	22,7
2017-12	24,7	22,8	26,7	2018-06	18,1	16,1	20,0




Figura 5.10: Previsione dei dodici mesi successivi con intervallo di confidenza al 95%.

La previsione riproduce correttamente il ciclo australe, con il minimo a luglio 2017 ($17,5^{\circ}\text{C}$), una crescita progressiva durante la primavera, il massimo a gennaio 2018 ($26,5^{\circ}\text{C}$) e un nuovo calo fino a giugno 2018 ($18,1^{\circ}\text{C}$).

L'intervallo di confidenza ha un'ampiezza media di circa $3,9^{\circ}\text{C}$ e resta sostanzialmente costante lungo l'orizzonte, invece di allargarsi progressivamente. Tutto ciò è coerente con quanto emerso nella validazione, infatti, il modello descrive un ciclo di fatto deterministico, per cui la previsione è governata dal profilo stagionale e l'incertezza non si accumula in modo marcato al crescere dell'orizzonte. L'affidabilità della previsione resta comunque subordinata all'assenza di cambiamenti strutturali nel regime climatico.

5.5 Sintesi e limiti

L'analisi ha applicato il ciclo di Box-Jenkins alla temperatura pomeridiana media mensile di Sydney, con un protocollo in cui tutte le scelte di modello sono basate sul solo training e il test è usato una sola volta.

La decomposizione ha evidenziato una stagionalità dominante di ampiezza $8,8^{\circ}\text{C}$ contro un residuo di $0,82^{\circ}\text{C}$, con forma additiva verificata da due criteri. La differenziazione stagionale, sostenuta dal KPSS e con l'ADF al limite della significatività, ha portato a $d = 0$, $D = 1$, $s = 12$. La lettura di ACF e PACF ha suggerito il SARIMA(1, 0, 0)(0, 1, 1)₁₂, risultato il migliore sia fra i candidati per AIC e BIC sia nella ricerca a griglia, e l'AIC ha indicato l'inclusione di una deriva. I residui superano il test di Ljung-Box a tutti i ritardi considerati.

La validazione a origine mobile ha confermato la scelta del SARIMA con deriva, il più parsimonioso fra modelli di accuratezza equivalente, e ha chiarito la struttura della serie. Il SARIMA e il modello con dummy mensili e trend producono errori quasi identici: il coefficiente MA stagionale vicino a -1 indica che la stagionalità è di fatto deterministica, e ciò

che distingue i modelli validi da quelli inadeguati è la presenza di un termine di tendenza. Sul test il modello scelto supera la baseline naïve stagionale del 10,3% sul MAE e del 9,9% sul RMSE, con bias quasi nullo. Le variabili esogene migliorano la previsione solo nello scenario oracolo, mentre in uno scenario realizzabile non portano vantaggi né in validazione né sul test.

I limiti dell'analisi sono i seguenti.

- Il training comprende 89 osservazioni, poco più di sette cicli annuali, e i fold di validazione usano finestre ancora più corte. La stima dei parametri stagionali e del trend è quindi incerta, come mostrano l'errore standard del coefficiente MA stagionale e la variabilità del trend nei primi fold.
- Ordini e termine deterministico sono scelti per AIC sull'intero training e poi tenuti fissi nei fold: la validazione confronta famiglie di modelli, non l'intera procedura di selezione.
- Il test è un'unica finestra di 24 mesi, per cui la stima finale dell'errore ha una variabilità non trascurabile. Il modello di Fourier con trend, migliore sul test ma equivalente in validazione, è un'alternativa da verificare su finestre di valutazione più ampie.
- L'analisi riguarda una sola località, e i risultati non sono automaticamente estendibili a stazioni con climi diversi.
- Le esogene sono previste con una semplice regola stagionale: covariate realmente anticipabili, come indici climatici a larga scala o previsioni meteorologiche di terze parti, potrebbero portare un beneficio che con questi dati non è stato possibile misurare.

Il progetto ha analizzato un unico dataset meteorologico, *weatherAUS*, con tre famiglie di tecniche: classificazione, clustering e analisi delle serie temporali. In ciascuna è stato adottato un protocollo pensato per evitare le fonti più comuni di risultati ottimistici. Questo capitolo riassume i risultati principali, mette in evidenza gli elementi metodologici comuni alle tre analisi e indica i possibili sviluppi.

6.1 Sintesi dei risultati

Il filo conduttore del lavoro è la struttura temporale dei dati, emersa già nell'analisi esplorativa, ovvero le osservazioni formano un panel di serie storiche, la pioggia è autocorrelata e il target di un giorno coincide con `RainToday` del giorno successivo. Questa proprietà ha orientato le scelte di tutti i capitoli, quali lo split cronologico e la validazione temporale nella classificazione, il campionamento casuale legittimo nel clustering, che descrive la struttura dei dati senza prevedere il futuro, e la modellazione esplicita del tempo nelle serie temporali.

Analisi esplorativa. L'EDA ha individuato le scelte da compiere prima della modellazione: quattro colonne con mancanti strutturali per intere stazioni, uno sbilanciamento del target di circa 3,5 : 1, una multicollinearità moderata fra temperature e pressioni (Condition Index 21) e la ridondanza fra `Rainfall` e `RainToday`. La riparametrizzazione in livelli e variazioni riduce il Condition Index a 4,3 e produce feature più correlate con il target, come l'escursione termica e la pioggia in scala logaritmica. Due scelte sono state lasciate aperte e risolte sperimentalmente nella classificazione, ovvero il recupero delle colonne sparse più informative e l'adozione della riparametrizzazione.

Classificazione. XGBoost è il modello migliore in tutte e quattro le configurazioni dello studio di ablazione. La configurazione che recupera `Sunshine` e `Cloud3pm` con indicatore di mancanza e applica la riparametrizzazione è la migliore in validazione incrociata temporale con PR-AUC 0,741 e ottiene sul test ROC-AUC pari a 0,886, PR-AUC a 0,737, Recall a 0,809 e F1 a 0,643. La soglia di decisione, calibrata su una matrice dei costi che penalizza tre volte le piogge mancate, riduce il costo atteso del 17% rispetto alla soglia di default; rispetto

alla baseline di persistenza la riduzione è del 42%. Le due domande lasciate aperte dall'EDA ricevono una risposta positiva, ma con miglioramenti modesti, dello stesso ordine della variabilità fra i fold. Uno split casuale avrebbe invece sovrastimato la PR-AUC di 2–3 punti, più dell'intero guadagno prodotto dalle scelte sulle feature.

Clustering. K-Means individua quattro regimi meteorologici interpretabili (freddo e stabile, mite e secco, caldo, perturbato e ventoso), coerenti con stagioni, piovosità e geografia pur senza avere usato queste informazioni nella fase di apprendimento. Nessun indice interno seleziona $k = 4$, infatti, la scelta deriva da una regola fissata in anticipo, basata sulla varianza spiegata, sulla non riducibilità della partizione a una singola variabile e sulla stabilità, che crolla a $k = 5$. DBSCAN non produce una partizione utilizzabile, perché le condizioni meteorologiche formano un continuo senza discontinuità di densità, ma è utile come rilevatore di anomalie; le giornate che isola corrispondono in larga parte al regime perturbato.

Serie temporali. Il SARIMA(1,0,0)(0,1,1)₁₂ con deriva, identificato da ACF e PACF sul solo training e confermato da AIC, ricerca a griglia e validazione a origine mobile, prevede la temperatura media mensile a Sydney con un MAE di 0,801 °C sui 24 mesi di test. Inoltre, esso supera la baseline naïve stagionale del 10%, con bias quasi nullo e residui a rumore bianco.

L'analisi ha chiarito anche la struttura della serie. In particolare, il SARIMA e un modello con dummy mensili e trend producono errori quasi identici, per cui la stagionalità risulta di fatto deterministica, e ciò che distingue i modelli validi da quelli inadeguati è la presenza di un termine di tendenza. Le variabili esogene migliorano la previsione (–17% di MAE) solo nello scenario *oracolo*, in cui se ne conoscono i valori futuri; dovendole prevedere, non portano vantaggi né in validazione né sul test.

6.2 Considerazioni metodologiche

Al di là dei singoli risultati, le tre analisi condividono alcuni principi che ne determinano l'affidabilità.

Separazione fra selezione e valutazione. In ogni analisi le scelte di modello sono state fatte senza usare i dati su cui il modello viene valutato. Nella classificazione configurazioni, iperparametri e soglie sono scelti con la validazione incrociata temporale, e il test è usato una sola volta. Nelle serie temporali l'analisi esplorativa, i test di stazionarietà e i correlogrammi sono calcolati sul solo training, e il confronto fra famiglie di modelli avviene con una validazione a origine mobile interna al training. Nel clustering, dove non esiste un test in senso stretto, lo stesso principio prende la forma della separazione fra le variabili usate per costruire i gruppi e quelle usate per validarli.

Regole di decisione dichiarate in anticipo. Le scelte che dipendono da un confronto numerico sono state guidate da criteri fissati prima di osservare i risultati, come ad esempio la minimizzazione del costo atteso per la soglia di classificazione, la stabilità e la non riducibilità per il numero di cluster e infine la regola dell'errore standard per il modello di serie temporali. Questo evita che la regola venga costruita a posteriori per giustificare il risultato preferito.

Confronto con baseline semplici. Ogni modello è stato confrontato con un riferimento elementare. Nella classificazione, la regola di maggioranza mostra quanto l'accuracy sia fuorviante e la persistenza fornisce il riferimento da battere; nelle serie temporali la baseline naïve stagionale misura lo spazio effettivamente disponibile per un modello più elaborato. In entrambi i casi il margine ottenuto è reale ma contenuto, perché una parte rilevante del segnale è catturata già dalla struttura più semplice dei dati, come la persistenza della pioggia e il ciclo annuale della temperatura.

Risultati negativi e artefatti dichiarati. I risultati che non confermano le ipotesi sono stati riportati come tali, perché documentano proprietà dei dati e giustificano le scelte adottate; questi sono il fallimento di DBSCAN come algoritmo di partizionamento, l'assenza di vantaggi delle esogene in uno scenario realizzabile e i guadagni modesti delle scelte sulle feature. Allo stesso modo, le condizioni che producono stime ottimistiche, come lo split casuale nella classificazione e lo scenario *oracolo* nelle serie temporali, sono state quantificate e presentate separatamente anziché escluse in silenzio.

6.3 Sviluppi futuri

Fra le estensioni possibili:

- estendere la ricerca degli iperparametri di XGBoost, i cui valori ottimali si trovano al bordo della griglia, e ripetere lo studio delle strategie per lo sbilanciamento direttamente su XGBoost, usando SMOTE-NC per trattare correttamente le variabili categoriche;
- tarare la matrice dei costi sul costo reale di una pioggia mancata, per cui l'analisi di sensibilità fornisce già il quadro dei compromessi possibili;
- eseguire il clustering sull'intero insieme di osservazioni complete anziché su un campione, e arricchire l'analisi geografica con attributi climatici delle stazioni;
- nelle serie temporali, valutare il modello su più finestre di test successive, per verificare se la rappresentazione della stagionalità con termini di Fourier e trend, migliore sul test ma equivalente in validazione, sia effettivamente preferibile;
- usare covariate realmente anticipabili, come indici climatici a larga scala o previsioni meteorologiche, ed estendere l'analisi ad altre località per verificare la stabilità degli ordini identificati.